

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN - TIN HỌC



BÁO CÁO TIỂU LUẬN MÔN HỌC DEEP LEARNING

NHÓM 10

**ỨNG DỤNG MÔ HÌNH HỌC SÂU TRONG DỊCH
MÁY PHƯƠNG NGỮ MIỀN TÂY SANG TIẾNG
VIỆT PHỔ THÔNG**

SINH VIÊN THỰC HIỆN

Nguyễn Đỗ Khánh Ngọc - 23280008

Thái Ngọc Thanh Mai - 23280018

Nguyễn Ngọc Minh - 23280029

GIẢNG VIÊN HƯỚNG DẪN

Hà Minh Tuấn

Tp. Hồ Chí Minh, tháng 06 năm 2026

Lời cam đoan

Nhóm nghiên cứu xin cam đoan báo cáo đồ án môn học này là công trình thực nghiệm do chính các thành viên trong nhóm thực hiện dưới sự giảng dạy và hướng dẫn trực tiếp từ giảng viên phụ trách bộ môn.

Toàn bộ số liệu thống kê khám phá (EDA), quy trình tiền xử lý cô lập dữ liệu chống rò rỉ (Data Leakage) và các kết quả đánh giá định lượng (BLEU, ROUGE-L) được trình bày trong báo cáo là hoàn toàn trung thực, khách quan. Các nguồn mã nguồn tham khảo hay hệ thống ngữ liệu kế thừa đều được nhóm khai báo và trích dẫn tường minh theo đúng quy định học thuật.

Tp. Hồ Chí Minh, ngày 13 tháng 06 năm 2026

Lời cảm ơn

Để hoàn thành báo cáo đồ án kết thúc môn học này một cách trọn vẹn, nhóm nghiên cứu xin được gửi lời cảm ơn chân thành nhất đến Thầy Hà Minh Tuấn - giảng viên phụ trách bộ môn. Những bài giảng lý thuyết chuyên sâu, kiến thức nền tảng vững chắc cùng những lời góp ý, định hướng chuyên môn quý báu của thầy trong suốt học kỳ qua đã giúp nhóm định hình và hoàn thiện đề tài một cách đúng đắn.

Do giới hạn về mặt thời gian và tài nguyên phần cứng thực nghiệm, đồ án khó tránh khỏi những thiếu sót nhất định trong quá trình tối ưu hóa siêu tham số và phân tích lỗi. Nhóm rất mong sẽ nhận được những nhận xét, đánh giá chuyên môn từ thầy để nhóm có thêm kinh nghiệm cải thiện mô hình trong các học phần tiếp theo.

Nhóm xin chân thành cảm ơn!

Tp. Hồ Chí Minh, ngày 13 tháng 06 năm 2026

Tập thể nhóm thực hiện

Mục lục

Lời cam đoan	i
Lời cảm ơn	i
Mục lục	ii
Danh sách hình	iv
Danh sách bảng	v
Lời nói đầu	vi
1 Mở đầu	1
1.1 Bài toán	1
1.2 Mục tiêu	1
1.3 Giới hạn tài nguyên	2
2 Cơ sở lý thuyết	4
2.1 Định nghĩa toán học của bài toán Dịch máy	4
2.1.1 Cơ chế khai triển chuỗi và xác suất có điều kiện	4
2.1.2 Không gian tìm kiếm và Thách thức giải mã	5
2.2 Phương pháp dịch dựa trên luật (Rule-Based Baseline)	5
2.2.1 Nguyên lý hoạt động	6
2.2.2 Đánh giá ưu điểm	6
2.2.3 Phân tích chuyên sâu các nhược điểm	7
2.2.4 Kết luận và động lực chuyển đổi kiến trúc	9
2.3 Các kiến trúc mạng nơ-ron	9
2.3.1 Mô hình Sequence-to-Sequence (Seq2Seq Bi-LSTM)	9
2.3.2 Mô hình học chuyển giao viT5 (Vietnamese Text-to-Text Transfer Transformer)	11
2.3.3 Mô hình Tinh chỉnh tham số hiệu quả (Transformer LoRA)	12
2.4 Hàm mục tiêu và Các cơ chế xử lý nhãn	14
2.4.1 Hàm Causal Cross-Entropy và Cơ chế che lấp (Masking)	14
2.4.2 Hàm mục tiêu SFT và Cơ chế truyền Gradient qua LoRA	15
2.5 Các kỹ thuật tối ưu hóa	16
2.5.1 Thuật toán tối ưu hóa AdamW và Kỹ thuật phân nhóm tham số	16

2.5.2	Lịch trình điều phối tốc độ học Linear Warmup và Linear Decay . .	17
2.5.3	Cắt xén Gradient (Gradient Clipping) và Cơ chế Dừng sớm (Early Stopping)	18
2.5.4	Các kỹ thuật tối ưu hóa đặc thù theo kiến trúc mô hình	18
2.6	Các thang đo đánh giá (Evaluation Metrics)	19
3	Dữ liệu & Phương pháp	22
3.1	Tổng quan về tập dữ liệu	22
3.2	Quy trình xây dựng và tăng cường dữ liệu	23
3.2.1	Trích xuất dữ liệu ban đầu	23
3.2.2	Tinh lọc và chuẩn hóa dữ liệu gốc	23
3.2.3	Phân chia và tăng cường dữ liệu (Data Augmentation)	23
3.2.4	Kỹ thuật Prompt Engineering trong sinh dữ liệu	24
3.3	Khám phá dữ liệu gốc (EDA)	25
3.4	Tiền xử lý và Chiến lược phân chia dữ liệu	28
3.5	Cấu trúc Pipeline	29
4	Thực nghiệm & Đánh giá	31
4.1	Thiết lập cấu hình và Siêu tham số thực nghiệm	31
4.2	Biểu đồ hội tụ (Learning Curves)	32
4.3	So sánh kết quả giữa các mô hình	32
4.3.1	Đánh giá dựa trên hàm mất mát (Loss)	33
4.3.2	Đánh giá dựa trên chỉ số BLEU và ROUGE-L	33
4.3.3	Ưu và khuyết điểm của việc đánh giá bằng Loss so với BLEU/ROUGE	34
4.4	Phân tích lỗi (Error Analysis)	35
4.4.1	Trực quan hóa bằng Wordcloud	35
4.4.2	Phân tích chi tiết trên 100 trường hợp lỗi ngẫu nhiên	35
5	Kết luận	38
5.1	Ý nghĩa thực tiễn của đề tài	38
5.1.1	Bảo tồn và phát huy di sản ngôn ngữ Nam Bộ	38
5.1.2	Hỗ trợ chuẩn hóa và tối ưu hóa văn bản trong môi trường hành chính	38
5.1.3	Tiềm năng tích hợp sâu vào hệ sinh thái AI	39
5.2	Đóng góp	39
5.3	Hạn chế còn tồn tại	40
5.4	Hướng phát triển trong tương lai	41
	Tài liệu tham khảo	42

Danh sách hình

3.1	Kết quả phân tích EDA trên bộ dữ liệu Phương ngữ Miền Tây.	26
4.1	Biểu đồ hội tụ hàm mất mát của các mô hình trong quá trình huấn luyện.	32
4.2	Wordcloud minh họa các từ vựng Miền Tây thường xuất hiện trong các câu dịch lỗi.	35
4.3	Các trường hợp dự đoán sai tiêu biểu trích xuất từ tập kiểm thử.	37

Danh sách bảng

3.1	Minh họa kết quả Tăng cường dữ liệu (Data Augmentation) qua LLM . . .	25
3.2	Kết quả đánh giá chất lượng kho ngữ liệu thô 10.511 câu trước tiên xử lý .	27
4.1	Tổng hợp siêu tham số huấn luyện và cấu hình kiến trúc của các mô hình .	31
4.2	Kết quả thử nghiệm dịch tiếng Miền Tây sang tiếng Phổ thông trên tập Test	33
5.1	Bảng phân công công việc của nhóm	44

Chương 1

Mở đầu

1.1 Bài toán

Tiếng Việt sở hữu hệ thống phương ngữ phong phú, trong đó ngôn ngữ vùng Đồng bằng sông Cửu Long (miền Tây Nam Bộ) mang nhiều nét đặc trưng riêng biệt về từ vựng và cấu trúc diễn đạt. Trong kỷ nguyên số, ngôn ngữ địa phương ngày càng được sử dụng rộng rãi trên các nền tảng mạng xã hội và hội thoại hàng ngày. Tuy nhiên, hầu hết các hệ thống Xử lý ngôn ngữ tự nhiên (NLP) hiện nay đều được huấn luyện trên tập dữ liệu tiếng Việt chuẩn phổ thông. Sự trượt pha này tạo ra một "rào cản ngôn ngữ", khiến các mô hình AI gặp khó khăn trong việc hiểu và xử lý dữ liệu thực tế mang đậm tính địa phương.

Nghiên cứu này tập trung vào bài toán Dịch máy phương ngữ: chuyển đổi câu văn miền Tây sang tiếng Việt phổ thông. Không chỉ đơn giản là bài toán dịch thuật, hướng nghiên cứu này còn đóng vai trò như một cầu nối giao tiếp, góp phần bảo tồn sự đa dạng văn hóa vùng miền nhưng vẫn đảm bảo tính tương thích của dữ liệu với các hệ thống máy tính hiện đại.

Kết quả của bài toán mở ra nhiều tiềm năng ứng dụng thực tế bao gồm:

- (1) Tiền xử lý dữ liệu (Data Preprocessing): Đóng vai trò bước đệm chuẩn hóa văn bản trước khi đưa vào các pipeline NLP phức tạp hơn như Phân tích cảm xúc (Sentiment Analysis) hay Trích xuất thông tin (Information Extraction) trên mạng xã hội.
- (2) Trợ lý ảo và Chatbot: Cải thiện trải nghiệm người dùng, giúp hệ thống chăm sóc khách hàng tự động hiểu và phản hồi chính xác ngôn ngữ của người dùng địa phương.
- (3) Phụ đề tự động: Hỗ trợ chuẩn hóa phụ đề (Captioning) cho các nội dung video, podcast hoặc chương trình truyền hình có yếu tố phương ngữ.

1.2 Mục tiêu

Nghiên cứu này được thực hiện với mục tiêu thiết lập một hệ thống thử nghiệm toàn diện (Comprehensive Benchmark) cho bài toán dịch máy phương ngữ miền Tây, thông qua việc so sánh 4 phương pháp tiếp cận có mức độ phức tạp tăng dần. Các mục tiêu cụ thể bao gồm:

Xây dựng đường cơ sở (Baseline): Triển khai phương pháp tiếp cận truyền thống sử dụng tập luật ánh xạ (Rule-based Mapping) nhằm thiết lập một cột mốc đánh giá cơ sở về tốc độ và độ chính xác ở cấp độ từ vựng.

Xây dựng mô hình từ đầu (Training from scratch): Thiết kế và huấn luyện kiến trúc mạng Seq2Seq với Bi-LSTM Encoder kết hợp cơ chế tập trung Luong (Luong Attention) và kỹ thuật ép buộc học tập (Teacher Forcing), nhằm đánh giá khả năng mô hình hóa chuỗi trên cơ sở dữ liệu đặc thù tự xây dựng.

Khai thác mô hình tiền huấn luyện (Transfer Learning): Kế thừa và tinh chỉnh toàn bộ tham số (Full Fine-tuning) kiến trúc Transformer đã được huấn luyện sẵn trên tiếng Việt (viT5-base). Phương pháp học chuyển giao này giúp khai thác tri thức ngôn ngữ tổng quát từ kho ngữ liệu khổng lồ để bù đắp cho sự thiếu hụt của tập dữ liệu phương ngữ quy mô nhỏ.

Tinh chỉnh tham số hiệu quả (Parameter-Efficient Fine-Tuning - PEFT): Nghiên cứu và triển khai kỹ thuật LoRA (Low-Rank Adaptation) trên nền mô hình viT5-base, cho phép huấn luyện dưới 1% tổng tham số trong khi vẫn đạt hiệu năng cạnh tranh so với Full Fine-tuning.

Đánh giá và so sánh (Ablation Study / Benchmarking): Thực nghiệm so sánh hiệu quả của bốn phương pháp dựa trên các tiêu chuẩn đo lường (BLEU Score, ROUGE Score, Validation Loss) và chi phí tài nguyên (VRAM, thời gian huấn luyện), từ đó rút ra kết luận khoa học về tính ứng dụng của từng phương pháp trong điều kiện tài nguyên hạn chế.

1.3 Giới hạn tài nguyên

Quá trình nghiên cứu và thực nghiệm phải đối mặt với các thách thức cốt lõi sau:

Giới hạn về dữ liệu (Tự xây dựng ngữ liệu): Hiện tại, chưa có tập dữ liệu song ngữ (Parallel Corpus) chuẩn hóa nào dành riêng cho cặp ngôn ngữ "Miền Tây — Phổ thông" được công bố mã nguồn mở. Nhóm nghiên cứu phải tự động xây dựng tập dữ liệu bao gồm khoảng 25.000 cặp từ/câu thông qua quá trình thu thập, làm sạch, ánh xạ và kiểm tra thủ công. Quy mô tập huấn luyện bị giới hạn đặt ra các thách thức lớn trong việc xử lý từ vựng hiếm (Out-of-Vocabulary — OOV) và các từ đa nghĩa phụ thuộc ngữ cảnh — đây cũng chính là động lực để áp dụng Transfer Learning thay vì chỉ huấn luyện từ đầu.

Giới hạn về tài nguyên tính toán (GPU VRAM): Trên môi trường GPU Tesla T4 (16GB VRAM), dù đã tận dụng mô hình Pre-trained Transformer thay vì huấn luyện từ đầu, việc nạp các tham số của mạng Transformer/LLM vào bộ nhớ và lưu trữ đồ thị tính toán (Computational Graph) vẫn tiêu tốn tài nguyên khổng lồ. Do đó, nhóm buộc phải thiết lập các ràng buộc khắt khe: giới hạn độ dài chuỗi tối đa (Max Sequence Length), thu nhỏ kích thước lô (Batch Size), và áp dụng kỹ thuật LoRA nhằm đóng băng phần lớn trọng số gốc, ngăn chặn hiện tượng tràn bộ nhớ (Out of Memory - OOM).

Giới hạn về thời gian và thất nút cổ chai tính toán: Bên cạnh giới hạn bộ nhớ, thời gian huấn luyện cũng là một rào cản lớn. Đặc biệt, kiến trúc Seq2Seq Bi-LSTM tích hợp Luong Attention bị giới hạn bởi bản chất xử lý tuần tự (Sequential processing) của mạng hồi quy. Các bước thời gian (Time-steps) phải được tính toán nối tiếp nhau, làm mất đi

khả năng tính toán song song (Parallelization) của GPU, dẫn đến thời gian huấn luyện và suy luận (Inference) kéo dài đáng kể. Điều này hạn chế không gian tìm kiếm siêu tham số (Hyperparameter tuning), buộc nhóm phải tự tối ưu hóa bộ điều phối tốc độ học (Linear Warmup/Decay) để đẩy nhanh tốc độ hội tụ thay vì rèn luyện mô hình trong số lượng Epochs quá lớn.

Chương 2

Cơ sở lý thuyết

2.1 Định nghĩa toán học của bài toán Dịch máy

Dịch máy nơ-ron (Neural Machine Translation - NMT) về bản chất là bài toán mô hình hóa ngôn ngữ có điều kiện (Conditional Language Modeling). Mục tiêu cốt lõi là thiết lập một hệ thống tính toán có khả năng ánh xạ một chuỗi token nguồn (Source sequence) thuộc không gian phương ngữ nguồn sang một chuỗi token đích (Target sequence) thuộc không gian ngôn ngữ phổ thông tương đương.

Giả sử chuỗi câu phương ngữ Miền Tây đầu vào được ký hiệu là $\mathbf{X}$ và được phân rã thành một tập hợp gồm T các phần tử từ vựng (tokens):

$$\mathbf{X} = (x_1, x_2, \dots, x_T) \quad (2.1)$$

Trong đó, mỗi token x_t thuộc về một tập từ điển nguồn xác định $\mathcal{V}_{src}$ ($x_t \in \mathcal{V}_{src}$). Nhiệm vụ của mô hình dịch máy là tìm kiếm một chuỗi câu tiếng Việt chuẩn phổ thông đầu ra $\mathbf{Y}^*$ bao gồm M tokens:

$$\mathbf{Y}^* = (y_1, y_2, \dots, y_M) \quad (2.2)$$

sao cho chuỗi này tối đa hóa xác suất có điều kiện toàn cục (Maximum A Posteriori - MAP) dựa trên ngữ cảnh chuỗi nguồn $\mathbf{X}$ cho trước:

$$\mathbf{Y}^* = \arg \max_{\mathbf{Y}} P(\mathbf{Y} | \mathbf{X}) \quad (2.3)$$

2.1.1 Cơ chế khai triển chuỗi và xác suất có điều kiện

Theo quy tắc tích toán học của lý thuyết xác suất và tính chất nhân quả (Causal property) trong sinh văn bản, xác suất có điều kiện của toàn bộ chuỗi đích $P(\mathbf{Y} | \mathbf{X})$ được bóc tách và phân rã thành tích của các xác suất có điều kiện tại từng bước thời gian giải mã m :

$$P(\mathbf{Y} | \mathbf{X}) = \prod_{m=1}^M P(y_m | y_1, y_2, \dots, y_{m-1}, \mathbf{X}) = \prod_{m=1}^M P(y_m | y_{<m}, \mathbf{X}) \quad (2.4)$$

Trong đó, biểu thức $y_{<m} = (y_1, \dots, y_{m-1})$ đại diện cho lịch sử các token đích đã được tạo ra ở các bước thời gian trước đó.

2.1.2 Không gian tìm kiếm và Thách thức giải mã

Trong pha huấn luyện (Training phase), mô hình áp dụng chiến lược *Teacher Forcing* hoặc *Scheduled Sampling*, nạp trực tiếp nhãn chuẩn $y_{<m}$ từ tập dữ liệu huấn luyện để tối ưu hóa hàm mất mát Cross-Entropy. Tuy nhiên, trong pha suy luận thực tế (Inference phase), chuỗi đích lý tưởng $\mathbf{Y}^*$ đòi hỏi phải duyệt qua một không gian tìm kiếm có kích thước phình to theo hàm mũ là $|\mathcal{V}_{tgt}|^M$, gây ra hiện tượng bùng nổ tổ hợp nghiêm ngặt.

Để giải quyết rào cản tính toán này và xấp xỉ giá trị tối ưu của phương trình MAP, nhóm nghiên cứu triển khai hai thuật toán giải mã có cơ chế bóc tách khác nhau:

- **Giải mã tham lam (Greedy Decoding):** Thực hiện tối ưu hóa cục bộ tại từng bước bằng cách chọn token có phân phối xác suất cao nhất tại bước hiện hành:

$$y_m = \arg \max_{v \in \mathcal{V}_{tgt}} P(v \mid y_{<m}, \mathbf{X}) \quad (2.5)$$

Phương pháp này có chi phí tính toán tuyến tính $\mathcal{O}(M)$ nhưng dễ rơi vào bẫy cực tiểu cục bộ và không thể sửa sai nếu một token ở bước trước bị chọn lỗi.

- **Giải mã chùm (Beam Search Decoding):** Duy trì đồng thời K giả thuyết (với K là hệ số `beam_size`) có tổng xác suất tích lũy Log-probability cao nhất ở mỗi bước thời gian. Nhằm tránh việc mô hình thiên vị các chuỗi câu dịch ngắn (do tích xác suất của chuỗi dài luôn có xu hướng nhỏ dần), nhóm tích hợp thêm cơ chế phạt độ dài (*Length Penalty*):

$$\text{Score}(\mathbf{Y}) = \frac{\sum_{m=1}^M \log P(y_m \mid y_{<m}, \mathbf{X})}{(5 + M)^\alpha / (5 + 1)^\alpha} \quad (2.6)$$

Với tham số điều hòa hệ số mũ $\alpha = 0.6$, cơ chế này chuẩn hóa điểm số một cách công bằng giữa các câu dịch ngắn và dài, nâng cao rõ rệt năng lực bảo toàn ngữ nghĩa toàn cục.

2.2 Phương pháp dịch dựa trên luật (Rule-Based Baseline)

Trước khi tiến tới các kiến trúc mạng nơ-ron phức tạp, nhóm thực hiện thiết lập mô hình cơ sở (Baseline) thông qua phương pháp dịch thuật dựa trên từ điển và tập luật (Rule-Based Machine Translation — RBMT). Đây là cách tiếp cận truyền thống nhằm đo lường năng lực “tối thiểu” của hệ thống khi không có tri thức từ mô hình ngôn ngữ lớn, đồng thời tạo ra một mốc tham chiếu định lượng để đánh giá mức độ cải thiện của các kiến trúc học sâu về sau.

2.2.1 Nguyên lý hoạt động

Phương pháp này vận hành dựa trên cơ chế ánh xạ trực tiếp (*Direct Mapping*) từ từ vựng phương ngữ sang từ vựng phổ thông thông qua một từ điển song ngữ tĩnh. Toàn bộ tri thức ngôn ngữ của hệ thống được đóng gói trong một bảng tra cứu $\mathcal{D} = \{(w_i^{\text{dial}}, w_i^{\text{std}})\}_{i=1}^{|\mathcal{D}|}$, trong đó mỗi cặp ánh xạ một từ phương ngữ sang một từ phổ thông duy nhất — không có ngữ cảnh, không có xác suất, không có ngoại lệ.

Quy trình xử lý gồm 3 bước tuần tự:

1. **Phân tách từ (Tokenization):** Câu đầu vào được tách thành danh sách các token đơn lẻ dựa trên khoảng trắng: $\mathbf{w} = (w_1, w_2, \dots, w_N)$. Đây là tokenization mức từ đơn giản nhất, không xử lý dấu câu, từ ghép hay từ viết tắt.
2. **Tra cứu ánh xạ (Look-up Table):** Với mỗi token w_i , hệ thống tra cứu từ điển $\mathcal{D}$:

$$\hat{w}_i = \begin{cases} \mathcal{D}(w_i) & \text{nếu } w_i \in \mathcal{D} \\ w_i & \text{nếu } w_i \notin \mathcal{D} \end{cases} \quad (2.7)$$

Nếu từ tồn tại trong từ điển, nó được thay thế bởi bản dịch phổ thông tương ứng; nếu không, giữ nguyên giá trị gốc.

3. **Tái tạo câu (Reconstruction):** Các token $(\hat{w}_1, \hat{w}_2, \dots, \hat{w}_N)$ sau khi được ánh xạ được nối lại thành chuỗi văn bản hoàn chỉnh bằng khoảng trắng.

Độ phức tạp thời gian của toàn bộ quy trình là $O(N \cdot |\mathcal{D}|)$ với tìm kiếm tuyến tính, hoặc $O(N)$ nếu từ điển được lưu bằng bảng băm (hash map) — vốn là cài đặt tiêu chuẩn trong thực tế.

2.2.2 Đánh giá ưu điểm

Mặc dù đơn giản, RBMT sở hữu một số tính chất khó đạt được ở các mô hình học sâu:

- **Tốc độ thực thi tức thời:** Không cần GPU/CPU, không cần forward pass qua hàng tỷ tham số. Với câu 20 từ và từ điển 10.000 mục, toàn bộ quá trình dịch hoàn tất trong vài micro-giây — nhanh hơn ViT5-LoRA khoảng 10^4 lần về mặt thời gian suy diễn.
- **Tính minh bạch và truy vết hoàn toàn:** Mọi quyết định dịch thuật đều có thể giải thích bằng một dòng trong từ điển. Khi hệ thống dịch sai, người phát triển có thể xác định nguyên nhân ngay lập tức mà không cần kỹ thuật interpretability phức tạp.

- **Kiểm soát từ vựng đặc thù:** Với các từ địa danh, danh từ riêng hay thuật ngữ chuyên ngành cần dịch nhất quán (ví dụ: “Vũng Tàu” không được dịch thành biến thể khác), RBMT đảm bảo tuyệt đối tính nhất quán này thông qua từ điển tĩnh — điều mà các mô hình neural đôi khi không đảm bảo được.

2.2.3 Phân tích chuyên sâu các nhược điểm

Tuy nhiên, chính sự đơn giản của RBMT lại là nguồn gốc của mọi giới hạn. Dưới đây là phân tích ba nhược điểm hệ thống, mỗi nhược điểm được minh họa bằng ví dụ cụ thể từ phương ngữ Miền Tây.

Mù ngữ cảnh (Context Blindness)

RBMT hoạt động theo mô hình *word-by-word*: mỗi token được xử lý độc lập, hoàn toàn tách rời khỏi các token xung quanh. Hệ quả trực tiếp là hệ thống mất khả năng xử lý **đa nghĩa** (polysemy) — hiện tượng cực kỳ phổ biến trong phương ngữ Miền Tây.

Xét từ “*tráo*” trong hai ngữ cảnh:

Câu đầu vào (phương ngữ)	Nghĩa đúng	RBMT dịch ra
“Nó tráo cái bóp của tui.”	đánh tráo, hoán đổi	<i>trố mắt cái bóp của tui</i>
“Nó tráo mắt nhìn tui.”	trố mắt, nhìn chăm chăm	<i>đánh tráo mắt nhìn tui</i>

Từ điển chỉ lưu được *một* ánh xạ duy nhất cho “tráo”. Dù nhóm chọn ánh xạ nào, hệ thống cũng sai ở 50% trường hợp — và trong thực tế, tỉ lệ sai còn cao hơn vì nhiều từ phương ngữ có từ 3 đến 5 nghĩa tùy ngữ cảnh.

Tương tự, từ “*đặng*” vừa có nghĩa là “để” (mục đích) vừa có nghĩa là “được” (kết quả), dẫn đến các lỗi như:

Câu gốc	Bản dịch RBMT (sai)
“Làm vậy đặng má vui.” (để má vui)	“Làm vậy <i>được</i> má vui.”
“Xin mãi mới đặng .” (mới được cho phép)	“Xin mãi mới <i>để</i> .”

Để giải quyết triệt để vấn đề này đòi hỏi mô hình phải có khả năng **word sense disambiguation** (WSD) — tức là hiểu nghĩa của từ dựa vào toàn bộ câu. Đây chính là năng lực cốt lõi mà cơ chế self-attention của Transformer cung cấp, nhưng RBMT hoàn toàn thiếu.

Bất lực trước cấu trúc ngữ pháp

Phương ngữ Miền Tây không chỉ khác phổ thông ở từ vựng mà còn ở **trật tự từ** và **cấu trúc ngữ pháp**. Khi RBMT thay thế từng từ mà không điều chỉnh cấu trúc câu,

đầu ra mang từ vựng phổ thông nhưng ngữ pháp vẫn là phương ngữ — tạo ra một thứ ngôn ngữ lai không tự nhiên.

Xét ví dụ với vị từ cuối câu — đặc trưng của phương ngữ Nam Bộ:

Câu gốc (phương ngữ)	Bản dịch RBMT
“Anh đi hông ?”	“Anh đi <i>không</i> ?”
“ Hổng biết làm sao hết .”	“ <i>Không</i> biết làm sao <i>hết</i> .” × (“hết” thừa)
“Tui hổng có rảnh đâu nha.”	“Tui <i>không</i> có <i>rảnh</i> <i>đâu</i> nha.” × (“đâu nha” không tự nhiên)

Trường hợp đơn giản (hàng đầu) RBMT xử lý được vì chỉ cần thay một từ. Nhưng khi câu chứa **quán ngữ** (fixed expression) hoặc **tiểu từ tình thái** đặc trưng phương ngữ kết hợp với nhau, việc dịch từng từ riêng lẻ phá vỡ hoàn toàn tính tự nhiên của câu.

Một ví dụ điển hình hơn với cấu trúc so sánh phương ngữ:

Câu gốc	RBMT
“Cái này ngon hơn cái kia nhiều hen .”	“Cái này <i>ngon hơn</i> cái kia <i>nhiều nhỉ</i> .” ×
<i>Đúng phải là: “Cái này ngon hơn cái kia nhiều đấy.”</i>	

Từ “hen” (tiểu từ tình thái cuối câu Miền Tây biểu thị sự đồng tình nhẹ) không có từ tương đương một-một trong phổ thông — nó phải được dịch khác nhau tùy theo ngữ cảnh cảm xúc của cả câu. RBMT không có cơ chế nào để xử lý điều này.

Không có khả năng tổng quát hóa

Đây là giới hạn căn bản nhất của RBMT: **hệ thống chỉ biết những gì đã được định nghĩa tường minh**. Mọi từ, cụm từ, hay biến thể chính tả không nằm trong từ điển đều bị trả về nguyên trạng, tạo ra văn bản lai không nhất quán.

Phương ngữ Miền Tây đặc biệt có nhiều biến thể chính tả theo cách phát âm địa phương:

Biến thể phương ngữ	Nghĩa chuẩn	RBMT xử lý được?
“hổng”	không	(nếu có trong dict)
“hổngg”	không	× (lỗi đánh máy biến thể)
“hong”	không	× (thiếu dấu)
“hông”	không	Tùy (nếu nhóm thêm vào dict)
“”	thích	× (ký tự lạ)

Thực tế dữ liệu thu thập từ mạng xã hội hay hội thoại tự nhiên chứa rất nhiều biến thể kiểu này. Một mô hình neural với subword tokenization (BPE hoặc SentencePiece như ViT5 sử dụng) có thể nhận diện “hổngg” qua các subword chia sẻ với “hổng”, nhưng RBMT thất bại hoàn toàn.

2.2.4 Kết luận và động lực chuyển đổi kiến trúc

Sự yếu kém của RBMT không phải do thiếu dữ liệu từ điển hay kỹ thuật cài đặt kém, mà xuất phát từ ba giới hạn kiến trúc không thể khắc phục: mù ngữ cảnh, bất lực cấu trúc, và không tổng quát hóa.

Ba giới hạn này đều có chung một căn nguyên: RBMT xử lý ngôn ngữ như một *bảng ánh xạ tĩnh*, trong khi ngôn ngữ tự nhiên — đặc biệt là phương ngữ giàu biến thể như tiếng Miền Tây — vận hành theo *các quan hệ phụ thuộc động* giữa từ với từ, từ với ngữ cảnh, và từ với ý định giao tiếp.

Đây chính là tiền đề thôi thúc nhóm chuyển sang kiến trúc học sâu — nơi các quan hệ phụ thuộc này được học tự động qua cơ chế self-attention của Transformer và được tinh chỉnh hiệu quả trên dữ liệu phương ngữ thông qua LoRA.

2.3 Các kiến trúc mạng nơ-ron

2.3.1 Mô hình Sequence-to-Sequence (Seq2Seq Bi-LSTM)

Mô hình Sequence-to-Sequence (Seq2Seq) tăng cường cơ chế tập trung đóng vai trò cốt lõi trong việc chuyển đổi chuỗi phương ngữ nguồn sang ngôn ngữ phổ thông đích. Hệ thống được cấu thành từ ba thực thể chính: Bộ mã hóa hai chiều (Bi-LSTM Encoder), Khung tính toán tương đồng (Luong Attention), và Bộ giải mã tuần tự (LSTM Decoder) tích hợp chiến lược kết hợp đa tầng.

Bộ mã hóa hai chiều (Bi-LSTM Encoder)

Encoder chịu trách nhiệm tiếp nhận chuỗi token nguồn thuộc phương ngữ miền Tây $X = (x_1, x_2, \dots, x_T)$, ánh xạ qua không gian nhúng liên tục $E_{src} \in \mathbb{R}^{V_{src} \times D_{embed}}$ kết hợp tầng Dropout để tăng khả năng tổng quát hóa. Nhóm triển khai cấu trúc mạng LSTM hai chiều (Bidirectional LSTM) nhằm thu giữ ngữ cảnh lập thể từ cả hai hướng của chuỗi ngôn ngữ.

Việc sử dụng kiến trúc hai chiều là cực kỳ quan trọng đối với việc xử lý phương ngữ. Tại mỗi bước thời gian i , mạng tính toán song song hai trạng thái ẩn:

$$\vec{h}_i = \text{LSTM}_{fwd}(e(x_i), \vec{h}_{i-1}), \quad \overleftarrow{h}_i = \text{LSTM}_{bwd}(e(x_i), \overleftarrow{h}_{i+1}) \quad (2.8)$$

Nhờ cơ chế này, khi mô hình xử lý một từ phương ngữ đặc thù (ví dụ: từ "đặng"), chiều tiến (LSTM_{fwd}) sẽ thu nhận thông tin của các từ đứng trước, trong khi chiều lùi (LSTM_{bwd}) sẽ thu nhận thông tin của các từ phía sau. Sự kết hợp thông tin hai chiều giúp mô hình xác định chính xác ngữ nghĩa của từ phương ngữ dựa trên ngữ cảnh toàn cục của câu trước khi ánh xạ sang từ phổ thông tương ứng.

Vectơ đầu ra toàn cục của Encoder tại mỗi vị trí là sự ghép nối trực tiếp của hai hướng:

$$h_i = [\vec{h}_i; \overleftarrow{h}_i] \in \mathbb{R}^{2 \cdot D_{hidden}} \quad (2.9)$$

Cơ chế tập trung toàn cục Luong Attention và Masking

Tại bước giải mã t , mô hình sử dụng trạng thái ẩn ở tầng trên cùng của Decoder (s_t) để truy vấn thông tin từ ma trận đầu ra Encoder (h_i) thông qua hàm liên hợp tuyến tính (General Score function):

$$\text{score}(s_t, h_i) = s_t^T \cdot W_a \cdot h_i \quad (2.10)$$

Kỹ thuật che lấp (Masking): Để ngăn chặn mô hình phân bổ trọng số chú ý vào các ký tự đệm vô nghĩa ($< PAD >$), nhóm áp dụng mặt nạ hệ số âm vô cực ($-\infty$) lên các vị trí tương ứng của score trước khi đi qua hàm Softmax. Điều này đảm bảo trọng số tập trung của các ký tự đệm triệt tiêu hoàn toàn về 0:

$$\alpha_{t,i} = \frac{\exp(\text{score}(s_t, h_i))}{\sum_{j=1}^T \exp(\text{score}(s_t, h_j))} \quad \text{với } x_i \neq \text{pad_idx} \quad (2.11)$$

Vectơ ngữ cảnh toàn cục c_t được tổng hợp bằng tổ hợp tuyến tính:

$$c_t = \sum_{i=1}^T \alpha_{t,i} h_i \quad (2.12)$$

Bộ giải mã (Decoder) và Cơ chế Input Feeding nâng cao

Decoder bản chất là một mạng LSTM đơn hướng. Tại mỗi bước t , đầu vào của mạng là sự ghép nối (concatenate) giữa vectơ nhúng của token bước trước $e(y_{t-1})$ và vectơ ngữ cảnh vừa tính toán c_t :

$$x_{lstm} = [e(y_{t-1}); c_t] \in \mathbb{R}^{D_{embed} + 2 \cdot D_{hidden}} \quad (2.13)$$

Mạng LSTM forward một bước để sinh ra trạng thái ẩn hiện hành s_t . Nhằm tăng cường dòng thông tin và giải quyết hiện tượng mất mát ngữ nghĩa khi giải mã chuỗi dài, nhóm áp dụng kiến trúc **Input Feeding** đa tầng tại lớp tuyến tính đầu ra (fc_out). Logits dự đoán trên toàn bộ từ điển được tính toán bằng cách kết hợp đồng thời ba nguồn tri thức:

$$\text{Logits}_t = W_{fc_out} \cdot [s_t; c_t; e(y_{t-1})] \quad (2.14)$$

Chiến lược giải mã và Suy luận (Inference Decoding)

Nhóm nghiên cứu cài đặt hai thuật toán giải mã độc lập phục vụ cho các pha thực nghiệm khác nhau:

- **Greedy Decoding:** Tại mỗi bước thời gian, mô hình thực hiện lựa chọn cục bộ phần tử có xác suất cao nhất bằng hàm $\text{argmax}(\text{Logits}_t)$ để làm đầu vào cho bước tiếp theo. Thuật toán này có ưu điểm về tốc độ tính toán tối ưu nhưng dễ rơi vào cực tiểu cục bộ.
- **Beam Search Decoding:** Nhằm khắc phục nhược điểm của Greedy Search, thuật toán duy trì một tập hợp gồm K (beam_size) giả thuyết có tổng xác suất tích lũy (Log-probabilities) cao nhất. Tại các điểm biên của chuỗi, nhóm áp dụng cơ chế phạt độ dài (Length Penalty) mũ 0.6 để chuẩn hóa điểm số, tránh hiện tượng mô hình thiên vị các câu dịch ngắn, giúp nâng cao đáng kể chỉ số BLEU thực tế.

2.3.2 Mô hình học chuyển giao viT5 (Vietnamese Text-to-Text Transfer Transformer)

Khác với mạng hồi quy tuần tự, kiến trúc nền tảng của viT5 kế thừa trực tiếp mạng Transformer (Vaswani et al., 2017) với đầy đủ hai khối mã hóa và giải mã (Encoder-Decoder). Sự kết hợp giữa khả năng xử lý chuỗi song song của Transformer và tri thức ngôn ngữ từ pha tiền huấn luyện giúp viT5 trở thành giải pháp cốt lõi cho bài toán chuyển ngữ.

Kiến trúc:

Sức mạnh mô hình hóa ngữ cảnh của viT5 xuất phát từ cơ chế Multi-Head Self-Attention. Với H đầu chú ý, mô hình chiếu chuỗi đầu vào xuống không gian $d_k = d/H$ chiều để tính toán điểm số tương đồng:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V} \quad (2.15)$$

Các đầu chú ý độc lập này sau đó được ghép nối và chiếu bởi trọng số W_O để tạo ra biểu diễn đa chiều:

$$\text{MHSA}(\mathbf{X}) = [\text{head}_1 \parallel \dots \parallel \text{head}_H] W_O \quad (2.16)$$

Cơ chế này cho phép mô hình đánh giá tầm quan trọng của mọi từ phổ thông xung quanh để dịch chính xác một từ phương ngữ đặc thù mà không bị giới hạn bởi khoảng cách vị trí trong câu.

Bên cạnh đó, do mạng loại bỏ hoàn toàn tính tuần tự, Positional Encoding được cộng trực tiếp vào biểu diễn của từ thông qua hàm lượng giác để duy trì thông tin về thứ tự:

$$\text{PE}_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d}}\right), \quad \text{PE}_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d}}\right) \quad (2.17)$$

Chiến lược tinh chỉnh toàn bộ tham số (Full Fine-tuning)

Đặc trưng đột phá của dòng mô hình T5 là việc đồng nhất hóa mọi bài toán Xử lý ngôn ngữ tự nhiên thành định dạng chuỗi sang chuỗi. Đối với hệ thống đề xuất, chuỗi câu miền Tây được truyền trực tiếp làm văn bản đầu vào và mô hình được tối ưu hóa để sinh ra chuỗi tiếng Việt chuẩn tương ứng ở đầu ra.

Để vượt qua rào cản thiếu hụt dữ liệu phương ngữ, phương pháp tinh chỉnh toàn bộ được áp dụng. Thay vì khởi tạo trọng số ngẫu nhiên, mô hình tái sử dụng trực tiếp bộ tham số đã được tiền huấn luyện trên kho ngữ liệu tiếng Việt khổng lồ (CC100-VI). Quá trình tinh chỉnh này yêu cầu mở khóa và cập nhật lại toàn bộ tập hợp trọng số Θ (khoảng 226 triệu tham số đối với phiên bản **viT5-base**). Ký hiệu tập dữ liệu song ngữ là $\mathcal{D} = \{(x^{(i)}, y^{(i)})\}_{i=1}^N$, mục tiêu của pha huấn luyện là tìm ra bộ trọng số tối ưu Θ^* thông qua việc cực tiểu hóa hàm mất mát trên toàn bộ không gian tham số:

$$\Theta^* = \arg \min_{\Theta} \mathbb{E}_{(x,y) \sim \mathcal{D}} [\mathcal{L}(f_{\Theta}(x), y)] \quad (2.18)$$

Mặc dù chiến lược này giúp mô hình tận dụng tối đa tri thức nền tảng tiếng Việt để thích nghi sâu sắc với cấu trúc phương ngữ Miền Tây, việc mở khóa toàn bộ tham số đồng nghĩa với việc không gian giả thuyết mở rộng tối đa. Hệ quả là quá trình huấn luyện tiêu tốn tài nguyên phần cứng (VRAM) khổng lồ và rất dễ dẫn đến hiện tượng quá khớp khi số lượng mẫu dữ liệu tinh chỉnh có giới hạn.

2.3.3 Mô hình Tinh chỉnh tham số hiệu quả (Transformer LoRA)

Để giải quyết thất nút cổ chai về tài nguyên và nguy cơ quá khớp của Full Fine-tuning, kỹ thuật Low-Rank Adaptation (LoRA) được áp dụng.

Động lực: Intrinsic Dimension

Fine-tuning toàn bộ mô hình ngôn ngữ lớn (LLM) đòi hỏi cập nhật $|\Theta| \sim 10^9$ tham số, gây tốn kém bộ nhớ và tính toán. Aghajanyan et al. (2021) chỉ ra rằng các mô hình được huấn luyện trước có *intrinsic dimension* thấp — tức là tồn tại một không gian con chiều thấp $r \ll d$ đủ để mô tả quỹ đạo tối ưu khi fine-tuning. Điều này gợi ý rằng phần cập nhật trọng số ΔW trong quá trình fine-tuning có hạng thực sự thấp.

Hu et al. (2022) kiểm nghiệm giả thuyết trên bằng cách phân tích $\Delta W = W_{\text{fine-tuned}} - W_{\text{pretrained}}$ và thấy rằng tỷ lệ singular value giảm rất nhanh, xác nhận cấu trúc low-rank.

Phân tích Low-Rank qua SVD

Cho ma trận trọng số gốc $W_0 \in \mathbb{R}^{d \times k}$. Phân rã giá trị kỳ dị đầy đủ của phần cập nhật:

$$\Delta W = U \Sigma V^{\top}, \quad U \in \mathbb{R}^{d \times d}, \Sigma = \text{diag}(\sigma_1, \dots, \sigma_{\min(d,k)}), V \in \mathbb{R}^{k \times k} \quad (2.19)$$

Khi ΔW có hạng thực sự bằng r , chỉ r singular value đầu khác không:

$$\Delta W \approx U_r \Sigma_r V_r^\top = \underbrace{(U_r \Sigma_r^{1/2})}_B \underbrace{(\Sigma_r^{1/2} V_r^\top)}_A \quad (2.20)$$

LoRA tham số hóa trực tiếp xấp xỉ này bằng cặp ma trận (B, A) thay vì tính SVD tường minh.

Công thức LoRA

Với ma trận trọng số $W_0 \in \mathbb{R}^{d \times k}$ bị **đóng băng**, LoRA thêm một nhánh song song:

$$h = W_0 x + \Delta W x = W_0 x + \frac{\alpha}{r} B A x \quad (2.21)$$

trong đó:

- $A \in \mathbb{R}^{r \times k}$: ma trận chiếu xuống (*down-projection*), khởi tạo theo $\mathcal{N}(0, \sigma^2)$.
- $B \in \mathbb{R}^{d \times r}$: ma trận chiếu lên (*up-projection*), khởi tạo bằng **0** để đảm bảo $\Delta W = 0$ tại bước đầu.
- $r \ll \min(d, k)$: hạng xấp xỉ, thường $r \in \{4, 8, 16, 32\}$.
- $\alpha > 0$: hệ số tỷ lệ, thường đặt $\alpha = r$ hoặc $\alpha = 2r$; tỷ số α/r đóng vai trò learning rate hiệu dụng cho ΔW .

Hiệu quả tham số

Số tham số cần huấn luyện so với fine-tuning đầy đủ:

$$|\Theta_{\text{LoRA}}| = r(d + k), \quad |\Theta_{\text{full}}| = dk, \quad \frac{|\Theta_{\text{LoRA}}|}{|\Theta_{\text{full}}|} = \frac{r(d + k)}{dk} \quad (2.22)$$

Với $d = k = 4096$ và $r = 8$: $\frac{8 \times 8192}{4096^2} \approx 0.39\%$ — tiết kiệm hơn $250\times$.

Vị trí áp dụng

LoRA được gắn vào các ma trận chiếu trong MHSA của mỗi lớp Transformer:

$$\{W_Q, W_K, W_V, W_O\} \quad (2.23)$$

Tùy cấu hình, có thể mở rộng sang các ma trận trong FFN (W_1, W_2). Thực nghiệm cho thấy áp dụng LoRA lên W_Q và W_V thường mang lại kết quả tốt nhất trên các tác vụ NLP.

Hợp nhất trọng số khi suy diễn

Sau khi huấn luyện xong, $\Delta W = \frac{\alpha}{r}BA$ được hợp nhất trực tiếp vào W_0 :

$$W_{\text{deploy}} = W_0 + \frac{\alpha}{r}BA \quad (2.24)$$

Nhờ đó **không phát sinh thêm độ trễ** (latency) so với mô hình gốc tại thời điểm suy diễn. Đây là ưu điểm nổi bật so với các phương pháp adapter cộng thêm lớp mới vào đồ thị tính toán.

So sánh với các phương pháp Fine-tuning khác

Phương pháp	Tham số huấn luyện	Thêm latency	Lưu trữ adapter
Full fine-tuning	$ \Theta $ (100%)	Không	Không
Adapter Layers	$\sim 1\%$	Có	Có
Prefix Tuning	$\sim 0.1\%$	Có	Có
LoRA	$\sim 0.1\text{--}1\%$	Không	Có

2.4 Hàm mục tiêu và Các cơ chế xử lý nhãn

2.4.1 Hàm Causal Cross-Entropy và Cơ chế che lấp (Masking)

Đối với bài toán sinh văn bản, quá trình huấn luyện của cả kiến trúc Seq2Seq và viT5 đều được tối ưu hóa thông qua hàm mất mát Cross-Entropy (Cross-Entropy Loss). Mục tiêu của hàm là cực tiểu hóa độ sai lệch giữa phân phối xác suất dự đoán của mô hình và phân phối thực tế của nhãn (ground truth). Công thức của hàm mất mát cho một chuỗi có độ dài M được biểu diễn như sau:

$$\mathcal{L} = -\frac{1}{M} \sum_{t=1}^M \sum_{v=1}^V y_{t,v} \log(\hat{y}_{t,v}) \quad (2.25)$$

Trong đó:

- V là kích thước của từ điển (Vocabulary Size).
- $y_{t,v}$ là giá trị nhãn thực tế (đạt giá trị 1 tại vị trí từ đúng và 0 ở các vị trí khác).
- $\hat{y}_{t,v}$ là xác suất dự đoán của mô hình cho từ v tại bước t .

Kỹ thuật che lấp (Masking) và Bỏ qua nhãn (Ignore Index)

Trong thực hành, các chuỗi dữ liệu trong cùng một lô (batch) thường có độ dài khác nhau và được đệm thêm các ký tự đặc biệt <PAD> để đồng bộ kích thước ma trận. Để đảm bảo tính chính xác, hàm loss được kết hợp với một mặt nạ (mask) nhằm bỏ qua

các ký tự đệm này. Điều này ngăn chặn hệ thống cập nhật trọng số dựa trên các khoảng trống vô nghĩa, giúp thuật toán tập trung hoàn toàn vào các token ngôn ngữ thực thụ.

Tùy thuộc vào kiến trúc, cơ chế che lấp này được cài đặt thông qua hai phương pháp:

- **Đối với Seq2Seq Bi-LSTM:** Hệ thống sử dụng tham số `ignore_index` tích hợp sẵn trong hàm Cross-Entropy để tự động triệt tiêu sai số tại các vị trí tương ứng với mã token đệm (`PAD_IDX`).
- **Đối với Transformer viT5:** Trước khi ma trận nhân (`labels`) được đưa vào hàm tính toán tổn thất của HuggingFace, toàn bộ các token đệm được thay thế ép buộc bằng hằng số âm (`-100`). Trong môi trường tính toán động, hằng số này chỉ thị cho hàm loss loại trừ hoàn toàn các vị trí đệm khỏi phép tính trung bình cộng gradient.

2.4.2 Hàm mục tiêu SFT và Cơ chế truyền Gradient qua LoRA

Đối với phương pháp tinh chỉnh tham số hiệu quả với LoRA, bản chất của quá trình tối ưu vẫn dựa trên việc thiết lập tập dữ liệu huấn luyện dạng giám sát theo cặp (x, y^*) — trong đó x đại diện cho chuỗi prompt ngữ Miền Tây đóng vai trò ngữ cảnh (prompt) và y^* đại diện cho chuỗi tiếng Việt phổ thông đích cần sinh ra (response).

Hàm mục tiêu Tinh chỉnh giám sát (Supervised Fine-Tuning - SFT)

Mô hình viT5 được huấn luyện theo nguyên lý tự hồi quy có giám sát, chỉ tiến hành tính toán giá trị tổn thất (loss) trên phần chuỗi đầu ra mã đích y^* , thay vì tính toán trên toàn bộ chuỗi phức hợp. Xác suất của chuỗi đích được khai triển điều kiện theo quy tắc xác suất:

$$p_{\theta}(\mathbf{y}^*) = \prod_{t=1}^{|y^*|} p_{\theta}(y_t^* \mid x, y_{<t}^*) \quad (2.26)$$

Hàm loss SFT thu được bằng cách lấy trung bình số mũ âm Cross-Entropy (tương đương với ước lượng hợp lý cực đại MLE) trên tổng độ dài chuỗi đích $|y^*|$:

$$\mathcal{L}_{\text{SFT}}(\theta) = -\frac{1}{|y^*|} \sum_{t=1}^{|y^*|} \log p_{\theta}(y_t^* \mid x, y_{<t}^*) \quad (2.27)$$

Cơ chế cập nhật Gradient qua cấu trúc mạng LoRA

Điểm cốt lõi tạo nên sự hiệu quả vượt trội về tài nguyên bộ nhớ của LoRA nằm ở luồng truyền ngược gradient. Do ma trận trọng số gốc W_0 của mô hình viT5 đã bị đóng băng hoàn toàn, toán tử đạo hàm riêng của hàm loss đối với các trọng số này sẽ triệt tiêu về không ($\nabla_{W_0} \mathcal{L} = 0$). Toàn bộ dòng năng lượng gradient lúc này được ép buộc truyền qua nhánh cập nhật hạng thấp $\Delta W = \frac{\alpha}{r} BA$.

Áp dụng quy tắc chuỗi (*Chain Rule*) trong giải tích ma trận, đạo hàm riêng của hàm mục tiêu theo hai ma trận có quyền cập nhật trọng số (*trainable*) A và B được xác định tường minh như sau:

$$\frac{\partial \mathcal{L}}{\partial A} = \frac{\alpha}{r} B^\top \frac{\partial \mathcal{L}}{\partial \Delta W}, \quad \frac{\partial \mathcal{L}}{\partial B} = \frac{\alpha}{r} \frac{\partial \mathcal{L}}{\partial \Delta W} A^\top \quad (2.28)$$

Trong đó, $\frac{\partial \mathcal{L}}{\partial \Delta W}$ là ma trận Jacobian của loss theo sự thay đổi trọng số tổng hợp (có kích thước tương thích $d \times k$).

Lưu ý kỹ thuật về tính ổn định: Do ma trận B được khởi tạo bằng ma trận không ($\mathbf{0}$) tại thời điểm bắt đầu huấn luyện, hệ quả toán học dẫn đến là $\nabla_A \mathcal{L} = \mathbf{0}$ tại bước (*step*) đầu tiên. Cơ chế này đóng vai trò như một bộ đệm tự nhiên giúp triệt tiêu hoàn toàn nguy cơ bùng nổ gradient (*gradient explosion*) ở các vòng lặp khởi đầu. Lúc này, chỉ có ma trận B nhận giá trị gradient khác không ($\nabla_B \mathcal{L} \neq \mathbf{0}$), cho phép B hội tụ dần và kéo theo sự tối ưu hóa nhịp nhàng của ma trận A , giúp quỹ đạo huấn luyện ban đầu cực kỳ ổn định.

2.5 Các kỹ thuật tối ưu hóa

Mặc dù ba kiến trúc mạng trong nghiên cứu (Seq2Seq Bi-LSTM, Transformer Full, và Transformer LoRA) sở hữu cấu trúc ma trận và cơ chế lan truyền tiến khác nhau, quá trình tối ưu hóa ngược của chúng đều chia sẻ chung các thuật toán nền tảng. Sự đồng nhất ở các bước cấu hình chung nhằm đảm bảo tính khách quan và công bằng khi tiến hành đánh giá đối chứng (*benchmarking*) hiệu năng, trước khi áp dụng các tùy chỉnh đặc thù cho từng kiến trúc.

2.5.1 Thuật toán tối ưu hóa AdamW và Kỹ thuật phân nhóm tham số

Để cập nhật trọng số hiệu quả, hệ thống sử dụng thuật toán tối ưu **AdamW** (*Adam with Decoupled Weight Decay*). Điểm vượt trội của AdamW là tách biệt hoàn toàn cơ chế suy giảm trọng số (*Weight Decay*) ra khỏi quá trình tính toán đạo hàm thích ứng, giúp ngăn chặn hiện tượng quá khớp hiệu quả.

Quá trình tối ưu hóa tại mỗi bước thời gian t được thực hiện qua các bước toán học cốt lõi:

1. **Tính toán trạng thái động lượng (Moments):** Ước lượng moment bậc một m_t (đại diện cho xu hướng trung bình trượt của gradient) và moment bậc hai v_t (đại diện cho phương sai bình phương của gradient) với các hệ số siêu tham số điều

hướng β_1, β_2 :

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (2.29)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (2.30)$$

Trong đó $g_t = \nabla_{\theta} \mathcal{L}(\theta_t)$ là ma trận gradient của hàm loss tại bước t .

2. **Hiệu chỉnh độ lệch (Bias Correction):** Loại bỏ độ lệch sơ khởi do các ma trận moment được khởi tạo bằng 0 ở những vòng lặp đầu tiên:

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (2.31)$$

3. **Cập nhật tham số kết hợp suy giảm trọng số tách rời:** Trọng số θ được cập nhật trực tiếp kết hợp hình phạt L2 thông qua hệ số suy giảm λ và tốc độ học η :

$$\theta_t = (1 - \eta\lambda) \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon} \quad (2.32)$$

Trong đó ε là hằng số làm mịn số học nhằm tránh lỗi chia cho không.

Kỹ thuật phân nhóm tham số (Parameter Grouping): Để bảo toàn năng lực chuẩn hóa nội bộ của mạng nơ-ron, nhóm nghiên cứu triển khai cơ chế rẽ nhánh tập hợp tham số trước khi đưa vào bộ tối ưu. Các ma trận trọng số chính (*weights*) được áp dụng đầy đủ hệ số phạt λ để kiểm soát độ phức tạp. Ngược lại, các tham số thiên kiến (*bias*) và các trọng số thuộc lớp chuẩn hóa (`LayerNorm.weight`, `layer_norm.weight`) được cô lập hoàn toàn và thiết lập mức suy giảm trọng số bằng 0.0, tránh việc triệt tiêu các hệ số hiệu chỉnh phân phối nền tảng.

2.5.2 Lịch trình điều phối tốc độ học Linear Warmup và Linear Decay

Tốc độ học không giữ cố định mà được điều chỉnh động theo từng bước huấn luyện thông qua bộ điều phối LambdaLR. Tiến trình bao gồm hai giai đoạn nối tiếp nhau:

$$\eta(t) = \begin{cases} \eta_{\max} \cdot \frac{t}{T_{\text{warm}}} & \text{khi } t \leq T_{\text{warm}} \\ \eta_{\max} \cdot \left(1 - \frac{t - T_{\text{warm}}}{T - T_{\text{warm}}}\right) & \text{khi } t > T_{\text{warm}} \end{cases} \quad (2.33)$$

- **Giai đoạn Khởi động (Linear Warmup):** Chiếm 10% tổng số bước huấn luyện toàn cục ($T_{\text{warm}} = 0.1 \cdot T$). Tốc độ học tăng dần tuyến tính từ 0 lên mức tối đa $\eta_{\max}$. Cơ chế này giúp ổn định các trọng số ở pha khởi đầu, ngăn chặn hiện tượng bùng nổ sai số khi mô hình tiếp nhận ngữ cảnh mới.
- **Giai đoạn Giảm dần (Linear Decay):** Ở các bước thời gian còn lại ($t > T_{\text{warm}}$),

tốc độ học giảm dần tuyến tính từ đỉnh $\eta_{\max}$ về mức 0.0. Kỹ thuật này ép các hàm tối ưu thu nhỏ bước nhảy khi đã tiến sát đến vùng đáy, giúp ghim các trọng số vào điểm cực tiểu toàn cục một cách mượt mà.

2.5.3 Cắt xén Gradient (Gradient Clipping) và Cơ chế Dừng sớm (Early Stopping)

Do sức chứa không gian trạng thái ẩn lớn, luồng gradient truyền ngược trong mạng rất dễ xảy ra hiện tượng bùng nổ (*Gradient Explosion*). Hệ thống giải quyết rủi ro này bằng cách áp dụng hàm `clip_grad_norm` lên toàn bộ các tham số có quyền cập nhật gradient. Chuẩn L2 của vector gradient được giới hạn cứng ở ngưỡng tối đa $\max_norm = 1.0$:

$$g_t = \min \left(1.0, \frac{1.0}{\|g_t\|_2} \right) \cdot g_t \quad (2.34)$$

Đồng thời, để triệt tiêu hiện tượng học vẹt dữ liệu ở các phân đoạn cuối, tiến trình huấn luyện được giám sát chặt chẽ bởi cơ chế Dừng sớm (*Early Stopping*). Nếu hàm tổn thất trên tập xác thực (*Validation Loss*) không ghi nhận bất kỳ sự cải thiện nào sau một số vòng lặp định sẵn (*patience*), hệ thống sẽ kích hoạt lệnh ngắt tự động và đóng băng bộ trọng số tốt nhất (*Best Checkpoint*) nhằm bảo toàn năng lực tổng quát hóa.

2.5.4 Các kỹ thuật tối ưu hóa đặc thù theo kiến trúc mô hình

Bên cạnh khung tối ưu hóa tổng thể, mỗi cấu trúc mạng được tích hợp các kỹ thuật điều phối riêng biệt nhằm phù hợp với giới hạn phần cứng và bản chất cơ chế tính toán của mô hình đó:

Mô hình Seq2Seq LSTM: Cơ chế Scheduled Teacher Forcing

Mạng hồi quy Seq2Seq rất dễ mắc phải lỗi tích lũy sai số chuỗi (*Exposure Bias*) trong pha giải mã do sự khác biệt giữa pha huấn luyện và pha suy luận. Để cân bằng giữa tốc độ học tập và năng lực tự sửa sai, nhóm nghiên cứu cài đặt chiến lược *Scheduled Teacher Forcing*. Tại mỗi epoch, hệ thống tính toán một tỷ lệ mớm từ chuẩn xác tf_ratio giảm dần tuyến tính từ mức bắt đầu (TF_Start) đến mức kết thúc (TF_End):

$$tf_ratio = TF_Start - \left(\frac{\text{Epoch}}{\text{Num_Epochs} - 1} \right) \cdot (TF_Start - TF_End) \quad (2.35)$$

Ở các epoch đầu, tỷ lệ này cao để mô hình nhanh chóng nắm bắt cấu trúc câu phổ thông chuẩn. Ở các epoch sau, tỷ lệ hạ thấp để ép mạng Decoder phải tự sử dụng từ vựng do chính nó dự đoán ở bước trước làm đầu vào cho bước sau, mô phỏng chính xác điều kiện suy luận thực tế.

Mô hình Transformer Full: Thách thức tài nguyên bộ nhớ đồ họa

Đối với phương pháp Full Fine-tuning, bộ tối ưu AdamW phải tính toán và lưu trữ ma trận gradient cùng hai trạng thái moment (m_t, v_t) cho toàn bộ 226 triệu tham số mở khóa của viT5-base. Thao tác này đẩy dung lượng bộ nhớ đồ họa yêu cầu lên mức cực hạn, vượt quá kích thước vật lý của mô hình nhiều lần. Để tránh lỗi tràn bộ nhớ (Out-of-Memory - OOM) trên cấu hình phần cứng giới hạn (16GB VRAM), nhóm nghiên cứu bắt buộc phải hạ cấu hình kích thước lô tính toán xuống mức tối thiểu ($batch\ size = 8$), biến đây thành mô hình có chi phí tài nguyên nặng nhất trong các pha thực nghiệm.

Mô hình Transformer LoRA: Tối ưu hóa hạng thấp và Kỹ thuật Mixed Precision

Trái ngược với thiết lập toàn phần, cấu trúc LoRA giải phóng hoàn toàn áp lực bộ nhớ đồ họa. Do các ma trận gốc W_0 bị đóng băng hoàn toàn, bộ tối ưu AdamW chỉ phải lưu trữ và cập nhật trạng thái động lượng cho duy nhất hai ma trận hạng thấp bổ sung là A và B . Quy mô tính toán lúc này được rút gọn triệt để, chỉ chiếm vốn vẹn 0.39% tổng số lượng tham số toàn mạng huấn luyện.

Để tối ưu hóa sâu hơn năng lực tính toán của phần cứng, mô hình kết hợp cơ chế **Độ chính xác hỗn hợp (Mixed Precision)**. Tiến trình truyền tiến (Forward Pass) và trích xuất gradient được thực hiện trên định dạng số thực dấu phẩy động bán chính xác ($FP16/BF16$) giúp tiết kiệm hơn 50% dung lượng VRAM và tăng tốc độ xử lý của các lõi phần cứng chuyên dụng. Ngược lại, việc tích lũy và cập nhật trọng số trong AdamW vẫn được duy trì ở định dạng toàn phần ($FP32$) để bảo toàn độ chính xác số học, ngăn chặn triệt để hiện tượng mất mát thông tin phương ngữ địa phương.

2.6 Các thang đo đánh giá (Evaluation Metrics)

Trong các bài toán sinh văn bản (Text Generation) và Dịch máy (Machine Translation), việc đánh giá chất lượng của chuỗi đầu ra không thể dựa trên các hàm mất mát (Loss function) thông thường hay độ chính xác tuyệt đối (Accuracy) như bài toán phân loại. Nguyên nhân là do một câu phương ngữ có thể được dịch thành nhiều câu phổ thông khác nhau nhưng vẫn đồng nghĩa.

Để giải quyết vấn đề này, nhóm nghiên cứu sử dụng hai thang đo đánh giá chuẩn mực nhất trong Xử lý ngôn ngữ tự nhiên: BLEU và ROUGE-L.

Chỉ số BLEU (Bilingual Evaluation Understudy)

Chỉ số BLEU, được đề xuất bởi Papineni et al. (2002), là thang đo phổ biến nhất trong dịch máy. Thuật toán này đánh giá chất lượng bản dịch tự động (Candidate) bằng cách đếm số lượng các cụm từ (N-gram) trùng khớp với bản dịch của chuyên gia (Reference).

Cơ sở toán học của BLEU bao gồm hai thành phần cốt lõi:

1. Độ chính xác N-gram có hiệu chỉnh (Modified N-gram Precision - p_n)

Để ngăn chặn việc mô hình sinh ra một từ đúng lặp đi lặp lại nhiều lần để "gian lận" điểm số, BLEU áp dụng phép đếm có cắt xén (clipping). Số lần xuất hiện của một n-gram trong câu dự đoán sẽ bị giới hạn bởi số lần xuất hiện tối đa của n-gram đó trong câu tham chiếu. Công thức tính độ chính xác p_n cho toàn bộ tập dữ liệu (corpus) được định nghĩa:

$$p_n = \frac{\sum_{C \in \{Candidates\}} \sum_{n-gram \in C} Count_{clip}(n-gram)}{\sum_{C' \in \{Candidates\}} \sum_{n-gram' \in C'} Count(n-gram')} \quad (2.36)$$

Trong đó, $Count_{clip}$ đảm bảo mỗi n-gram chỉ được tính điểm tối đa bằng số lần nó xuất hiện trong câu đáp án chuẩn.

2. Hình phạt câu dịch ngắn (Brevity Penalty - BP)

Độ chính xác N-gram tự thân nó không thể phạt các câu dịch quá ngắn (ví dụ: mô hình chỉ dịch đúng 1 từ rồi dừng lại thì p_1 vẫn bằng 100%). Do đó, cơ chế Brevity Penalty (BP) được đưa vào để trừng phạt các bản dịch có độ dài ngắn hơn độ dài của câu tham chiếu.

$$BP = \begin{cases} 1 & \text{nếu } c > r \\ e^{(1-r/c)} & \text{nếu } c \leq r \end{cases} \quad (2.37)$$

Trong đó: c là tổng chiều dài của các câu dự đoán (candidate length) và r là tổng chiều dài của các câu tham chiếu (reference length).

Công thức BLEU tổng quát Chỉ số BLEU cuối cùng là tích của Hình phạt độ dài (BP) và trung bình nhân (Geometric Mean) của các độ chính xác n-gram (thường dùng từ 1-gram đến 4-gram), với w_n là trọng số cho mỗi n-gram (thường $w_n = 1/N$):

$$BLEU = BP \cdot \exp \left(\sum_{n=1}^N w_n \log p_n \right) \quad (2.38)$$

Giới hạn của BLEU đối với phương ngữ: Mặc dù BLEU là tiêu chuẩn vàng, nhưng trong bối cảnh dịch phương ngữ Miền Tây, phần lớn cấu trúc câu (các từ phổ thông) được giữ nguyên, chỉ thay đổi các từ lóng địa phương. Điều này tạo ra một "điểm mù" (Blind spot) khiến BLEU có thể chấm điểm rất cao cho một câu dịch sai hoàn toàn từ khóa trọng tâm, buộc nhóm nghiên cứu phải kết hợp thêm các phương pháp phân tích lỗi định tính (Error Analysis) ở phần sau.

Chỉ số ROUGE-L (Recall-Oriented Understudy for Gisting Evaluation)

Nếu BLEU tập trung vào Độ chính xác (Precision), thì dòng thang đo ROUGE lại chú trọng vào Độ phủ (Recall). Cụ thể, nghiên cứu này sử dụng ROUGE-L, dựa trên thuật toán tìm Chuỗi con chung dài nhất (Longest Common Subsequence - LCS).

Thuật toán LCS tìm kiếm chuỗi các từ xuất hiện theo cùng một thứ tự trong cả hai

câu (dự đoán và tham chiếu) mà không bắt buộc phải đứng liền kề nhau. Ưu điểm của ROUGE-L là nó tự động đánh giá được cấu trúc câu ở cấp độ toàn cục.

Giả sử câu tham chiếu X có độ dài m , câu dự đoán Y có độ dài n , các chỉ số ROUGE-L được tính toán như sau:

$$R_{lcs} = \frac{LCS(X, Y)}{m} \quad (\text{Độ phủ - Recall}) \quad (2.39)$$

$$P_{lcs} = \frac{LCS(X, Y)}{n} \quad (\text{Độ chính xác - Precision}) \quad (2.40)$$

$$F_{lcs} = \frac{(1 + \beta^2)R_{lcs}P_{lcs}}{R_{lcs} + \beta^2 P_{lcs}} \quad (\text{F-Score đo lường cuối cùng}) \quad (2.41)$$

Trong đó, β là tham số điều chỉnh tỷ trọng giữa Precision và Recall. Chỉ số F_{lcs} (hay ROUGE-L F1-Score) chính là thước đo được nhóm báo cáo tại phần đánh giá thực nghiệm nhằm đối chiếu chéo với kết quả của BLEU.

Chương 3

Dữ liệu & Phương pháp

3.1 Tổng quan về tập dữ liệu

Trong lĩnh vực Xử lý ngôn ngữ tự nhiên (NLP), chất lượng và quy mô của tập dữ liệu đóng vai trò quyết định đến hiệu suất của các mô hình học sâu. Tuy nhiên, đối với bài toán dịch máy phương ngữ từ tiếng Miền Tây sang tiếng Việt phổ thông, hiện tại chưa có sẵn một kho ngữ liệu song ngữ hoàn chỉnh và đạt chuẩn trên các nền tảng mở. Sự thiếu hụt này tạo ra rào cản lớn, bởi các kiến trúc mạng nơ-ron đòi hỏi một lượng dữ liệu đủ lớn và đa dạng để có thể nắm bắt được cả cấu trúc ngữ pháp cốt lõi của tiếng Việt lẫn các quy luật chuyển ngữ đặc thù.

Đứng trước giới hạn về mặt tài nguyên, nhóm nghiên cứu đã quyết định tự xây dựng tập dữ liệu từ đầu thông qua phương pháp thu thập, tổng hợp từ các tài liệu chuyên khảo và ứng dụng khả năng của các mô hình ngôn ngữ lớn. Nguồn dữ liệu ban đầu được lựa chọn là cuốn *"Từ điển từ ngữ Nam Bộ"* của tác giả Huỳnh Công Tín. Đây là tài liệu cung cấp nền tảng từ vựng phong phú, bao gồm các từ địa phương, định nghĩa chi tiết và các câu ví dụ minh họa ngữ cảnh. Nhóm đã tiến hành trích xuất các câu ví dụ này và sử dụng LLM để tự động dịch sang câu tiếng Việt phổ thông tương ứng, tạo thành các cặp dữ liệu song ngữ bước đầu.

Sau bước chuyển ngữ, quá trình tinh lọc dữ liệu được thực hiện một cách nghiêm ngặt. Phân tích thực tế cho thấy trong từ điển có chứa nhiều từ ngữ cổ, các từ lóng đã bị mai một hoặc không còn tính ứng dụng cao trong giao tiếp hiện đại. Để đảm bảo tính thực tiễn của mô hình khi triển khai, các phần dữ liệu lỗi thời này đã được lọc bỏ hoàn toàn.

Hệ quả của bước làm sạch này là quy mô tập dữ liệu bị thu hẹp đáng kể, chỉ còn lại khoảng 8.000 cặp câu. Đây là một dung lượng quá khiêm tốn, dễ dẫn đến hiện tượng quá khớp (overfitting) khi huấn luyện các mạng học sâu. Để giải quyết bài toán thất nút cổ chai về dữ liệu, nhóm nghiên cứu đã triển khai kỹ thuật tăng cường dữ liệu (Data Augmentation). Cụ thể, dựa trên các cặp câu (Miền Tây - Phổ thông) gốc đã được chuẩn hóa, LLM được tái sử dụng để sinh ra các biến thể câu mới. Các biến thể này sở hữu cấu trúc từ vựng và cách diễn đạt khác biệt nhưng vẫn bảo toàn trọn vẹn ngữ nghĩa của câu gốc. Phương pháp này không chỉ giúp nhân bản số lượng dữ liệu đạt mức kỳ vọng mà còn làm phong phú thêm không gian ngữ cảnh, giúp mô hình dịch thuật nâng cao khả năng tổng quát hóa trên dữ liệu thực tế.

3.2 Quy trình xây dựng và tăng cường dữ liệu

3.2.1 Trích xuất dữ liệu ban đầu

Để xây dựng nền tảng ngữ liệu mang tính chuẩn xác cao về mặt học thuật và văn hóa, nhóm nghiên cứu đã lựa chọn cuốn "*Từ điển từ ngữ Nam Bộ*" của PGS.TS Huỳnh Công Tín làm nguồn dữ liệu ban đầu. Đây là một công trình nghiên cứu ngôn ngữ học đồ sộ, hệ thống hóa hàng ngàn từ vựng, thành ngữ và cụm từ địa phương đặc trưng của vùng Nam Bộ nói chung và khu vực Đồng bằng sông Cửu Long nói riêng. Điểm giá trị nhất của tài liệu này đối với bài toán xử lý ngôn ngữ tự nhiên là bên cạnh việc giải thích ngữ nghĩa, tác giả còn cung cấp hệ thống các câu ví dụ minh họa. Các câu ví dụ này được đặt trong những ngữ cảnh giao tiếp cụ thể, phản ánh chính xác cấu trúc ngữ pháp, thói quen sử dụng đại từ và văn phong sinh hoạt đời thường của người dân bản địa.

Từ tài liệu này, nhóm tiến hành trích xuất từ vựng miền Tây và các câu ví dụ minh họa ngữ cảnh. Sau khi có được dữ liệu thô, nhóm thiết lập các câu lệnh (*prompt*) cho LLM để dịch các câu ví dụ mang phương ngữ sang tiếng Việt phổ thông, hình thành một tập dữ liệu song ngữ cơ sở. Để đảm bảo tính chính xác, LLM được cung cấp trước từ vựng địa phương và định nghĩa làm ngữ cảnh đối chiếu trước khi thực hiện tác vụ dịch thuật.

3.2.2 Tinh lọc và chuẩn hóa dữ liệu gốc

Sau bước chuyển ngữ, một quy trình tinh lọc (*filtering*) tự động được triển khai thông qua LLM để loại bỏ các mẫu dữ liệu nhiễu. Hệ thống tiến hành đánh cờ (*flagging*) và loại bỏ các trường hợp vi phạm hai tiêu chí: (1) Câu chứa từ vựng quá cổ xưa, không còn tính ứng dụng trong giao tiếp hiện đại (như: *son giá, lang sa, bâu,...*); (2) Bản dịch tiếng Việt phổ thông bị sai lệch ngữ nghĩa hoặc phá vỡ cấu trúc so với câu gốc. Kết thúc quá trình tinh lọc khắt khe này, nhóm nghiên cứu thu được một tập dữ liệu gốc sạch, đảm bảo chất lượng với quy mô khoảng 8.000 cặp câu.

3.2.3 Phân chia và tăng cường dữ liệu (Data Augmentation)

Với quy mô khoảng 10.511 cặp câu, dữ liệu vẫn chưa đủ lớn để tối ưu hóa các kiến trúc mạng học sâu phức tạp. Tuy nhiên, để ngăn chặn tuyệt đối hiện tượng rò rỉ dữ liệu và đảm bảo tính khách quan khi đánh giá mô hình, nhóm nghiên cứu quyết định thực hiện phân chia tập dữ liệu (Train/Validation/Test) trước khi tiến hành tăng cường dữ liệu. Tập Validation và tập Test được trích xuất trực tiếp từ nguồn khoảng 10.511 câu chuẩn nguyên bản này và được đóng băng hoàn toàn.

Sau khi cô lập tập kiểm thử, kỹ thuật sinh dữ liệu tổng hợp mới được áp dụng duy nhất trên tập Train. Bằng việc sử dụng LLM trong vai trò chuyên gia ngôn ngữ, với mỗi cặp câu trong tập Train, hệ thống tự động sinh thêm 3 biến thể mới đáp ứng các ràng

buộc chặt khe:

- **Bảo toàn đặc trưng:** Sinh câu bằng khẩu ngữ bình dân Nam Bộ, áp dụng kỹ thuật chỉ thị phủ định nghiêm cấm sử dụng từ lóng mạng xã hội hoặc Gen Z để giữ gìn tính nguyên bản.
- **Đảm bảo ánh xạ:** Từ vựng miền Tây mục tiêu trong câu biến thể phải được giữ nguyên hoặc chuyển đổi tương đương sang từ phổ thông trong câu đích.
- **Kiểm soát độ dài:** Mọi câu sinh ra bị giới hạn tuyệt đối không quá 40 từ nhằm kiểm soát tài nguyên VRAM khi huấn luyện.

Nhờ chiến lược này, tập Train được mở rộng lên 25.000 cặp câu, cung cấp không gian ngữ cảnh đa dạng cho mô hình học tập, trong khi tập Test vẫn giữ được tính nguyên bản, phản ánh đúng khả năng tổng quát hóa của mô hình trên dữ liệu thực tế.

3.2.4 Kỹ thuật Prompt Engineering trong sinh dữ liệu

Để đảm bảo các biến thể dữ liệu được sinh ra bởi Mô hình ngôn ngữ lớn (LLM) giữ được độ nguyên bản của phương ngữ và có thể tích hợp tự động vào luồng dữ liệu (Data Pipeline), nhóm nghiên cứu đã thiết kế một hệ thống Dấu nhắc (Prompt) tinh vi. Quá trình này áp dụng các kỹ thuật Prompt Engineering nâng cao, bao gồm Thiết lập vai trò (Role-playing), Ràng buộc phủ định (Negative Constraints) và Ép kiểu định dạng đầu ra (Format Forcing).

Cấu trúc lệnh Prompt chi tiết được nhóm triển khai trên hệ thống như sau:

Ngữ cảnh (System Prompt): Bạn là một chuyên gia ngôn ngữ Nam Bộ.
Dưới đây là danh sách các cặp câu [Miền Tây gốc] – [Phổ thông gốc].
Nhiệm vụ: Với MỖI cặp câu gốc, hãy sinh ra thêm 3 cặp câu biến thể mới có cùng ý nghĩa để làm giàu dữ liệu.

QUY ĐỊNH BẮT BUỘC KHI SINH CÂU:

1. Câu [Miền Tây mới]: Phải dùng khẩu ngữ, văn nói tự nhiên, bình dân hàng ngày của người dân Nam Bộ đời thực.
2. NGHIÊM CẤM dùng từ lóng Gen Z hoặc từ lóng mạng xã hội (TUYỆT ĐỐI KHÔNG dùng: xỉu up xỉu down, xu cà na, ét ô ét, chằm kềm, lướt top top, cá bống, bắt lực...).
3. Câu [Phổ thông mới]: Diễn đạt lại ý nghĩa bằng từ ngữ phổ thông chuẩn xác, tự nhiên, khác với câu phổ thông gốc để tạo sự đa dạng từ vựng.
4. YÊU CẦU ÁNH XẠ (MAPPING): Mỗi từ ngữ "đặc sản" miền Tây trong câu [Miền Tây mới] PHẢI được giải nghĩa hoặc chuyển đổi trực tiếp sang từ phổ thông tương đương trong cùng một cặp câu [Phổ thông mới].

5. Giới hạn độ dài: Mọi câu sinh ra TUYỆT ĐỐI KHÔNG QUÁ 40 TỪ. Ưu tiên câu ngắn, súc tích đúng chất văn nói.
6. KHÔNG dùng tiếng Anh. KHÔNG giải thích. CHỈ trả về đúng khối JSON duy nhất theo định dạng mảng (Array).

Kết quả thực nghiệm: Bảng 3.1 minh họa kết quả thực tế của quá trình tăng cường dữ liệu thông qua cấu trúc Prompt trên. Từ 1 mẫu gốc, hệ thống thu về 3 biến thể mới với không gian ngữ cảnh và từ vựng được mở rộng nhưng vẫn giữ nguyên vẹn ý nghĩa cốt lõi.

Bảng 3.1: Minh họa kết quả Tăng cường dữ liệu (Data Augmentation) qua LLM


Phân loại	Câu Phương ngữ (Nguồn)	Câu Phổ thông (Đích)
Cặp câu gốc	Bữa nay tui thấy người nó lừ đừ , chắc tại thời tiết đổi mùa.	Hôm nay tôi thấy người uể oải , chắc do thời tiết chuyển mùa.
Biến thể 1	Trời trở gió làm trong mình tui ê ẩm, lừ đừ quá mạng.	Trời chuyển gió làm cơ thể tôi nhức mỏi, mệt mỏi vô cùng.
Biến thể 2	Hồng hiệu sao nay lừ đừ trong mình, chắc trúng gió rồi.	Không hiểu sao hôm nay cơ thể lờ đờ , chắc bị cảm rồi.
Biến thể 3	Thời tiết ngộ ghê, làm tui lừ đừ muốn bệnh luôn vậy đó.	Thời tiết lạ thật, làm tôi mệt mỏi như sắp ốm vậy.

3.3 Khám phá dữ liệu gốc (EDA)

Tập dữ liệu song ngữ đặc thù ban đầu sau quá trình thu thập và gán nhãn thủ công nghiêm ngặt ghi nhận tổng cộng 10.511 mẫu bao gồm (Từ, ý nghĩa, câu miền tây và câu phổ thông). Quá trình khám phá dữ liệu thực nghiệm được tiến hành trên tập dữ liệu gốc này nhằm xác lập các đặc trưng phân phối và định hình hệ số cấu hình cho mạng Seq2Seq Bi-LSTM.

Dựa trên kết quả khảo sát chi tiết được thể hiện trực quan qua Hình 3.1, nhóm nghiên cứu rút ra các đặc tính hình học cốt lõi của kho ngữ liệu như sau:

- **Phân phối độ dài từ (Cấp độ ký tự):** Biểu đồ đầu tiên biểu diễn độ dài của các từ miền Tây tính theo số ký tự. Kết quả ghi nhận giá trị trung bình đạt $\mu = 8.4$ ký tự/từ. Phần lớn các từ tập trung mật độ cao trong khoảng từ 5 đến 15 ký tự, phản ánh tính chất phân bố chiều dài từ vựng đặc trưng trong ngôn ngữ tự nhiên tiếng Việt.
- **Đặc trưng phân phối độ dài câu (Cấp độ số từ):**
 - **Câu ví dụ phương ngữ (Source):** Có độ dài trung bình đạt $\mu = 11.1$ từ. Dựa vào đồ thị mật độ tích lũy, phân vị số 95 (Percentile 95) đạt giá trị $P_{95} = 17$ từ.



Hình 3.1: Kết quả phân tích EDA trên bộ dữ liệu Phương ngữ Miền Tây.

- **Câu dịch phổ thông (Target):** Có độ dài trung bình đạt $\mu = 11.9$ từ. Phân phối có xu hướng dịch chuyển nhẹ về phía bên phải so với câu nguồn.
- **Nhận xét ngôn ngữ học:** Việc độ dài trung bình của câu phương ngữ thấp hơn câu phổ thông tái khẳng định đặc tính giản lược, cô đọng và mang tính khẩu ngữ cao của người dân Nam Bộ trong giao tiếp thực tế.

Song song với việc phân tích đặc trưng hình học, nhóm nghiên cứu cũng tiến hành một quy trình kiểm định chất lượng toàn diện (Data Quality Audit) trên tập dữ liệu thô này ngay sau khi trích xuất. Kết quả khảo sát định lượng thực tế trước khi đưa vào pipeline tiền xử lý được thống kê chi tiết tại Bảng 3.2.

Từ các chỉ số thống kê của Bảng 3.2, nhóm triển khai các cấu hình kỹ thuật nền tảng cho hệ thống:

- **Xác lập tham số chặn chuỗi (Max Sequence Length):** Dựa trên chỉ số phân vị $P95 = 17$ từ của câu ví dụ phương ngữ, nhóm quyết định thiết lập tham số $Max_Sequence_Length = 17$ từ cho mô hình. Ngưỡng chặn này giúp triệt tiêu các câu ngoại lai quá dài, loại bỏ việc độn quá nhiều mã đệm <PAD> vô nghĩa vào ma trận lô (batch matrix), từ đó tối ưu hóa tối đa dung lượng bộ nhớ đồ họa GPU VRAM nhưng vẫn bảo toàn trọn vẹn ngữ nghĩa của 95% số lượng mẫu trong kho dữ liệu. Đồng thời, việc loại bỏ chính xác 22 bản ghi trùng lặp được ghi nhận ở

Bảng 3.2: Kết quả đánh giá chất lượng kho ngữ liệu thô 10.511 câu trước tiền xử lý

Tiêu chí kiểm định	Trạng thái thực tế	Số lượng lỗi	Đánh giá và Hướng xử lý kỹ thuật
Trùng lặp bản ghi (Duplicate Records)	Xuất hiện trùng lặp nhỏ	22 câu	Phát sinh do một số câu ví dụ được tái sử dụng giữa các mục từ có nghĩa tương đồng trong từ điển; xử lý triệt để bằng <code>drop_duplicates()</code> .
Nhiều ký tự đặc biệt (Text Noise & Garbage)	Hoàn toàn sạch	0 câu	Không xuất hiện các ký tự rác, dấu ngoặc thừa hay lỗi định dạng thô nhờ quy trình kiểm soát nghiêm ngặt lúc trích xuất.
Lỗi phong chữ và mã hóa (Encoding Issues)	Đạt chuẩn UTF-8	0 câu	100% các bản ghi tuân thủ đồng nhất bảng mã Unicode dựng sẵn, không bị lỗi hiển thị phong chữ tiếng Việt.
Khuyết thiếu trường (Missing/Null Value)	Đầy đủ thông tin	0 câu	Không tồn tại bất kỳ ô trống hay giá trị null nào ở cả hai trường câu nguồn (Miền Tây) và câu đích (Phổ thông).
Chuỗi ngoại lai quá dài (Length Outliers)	Kiểm soát tốt	0 câu	Phần lớn các câu nằm trong phân phối tự nhiên; các câu dài được quản lý trực tiếp bằng tham số <code>Max_Sequence_Length = 17</code> ở pha cấu hình mô hình.

bảng trên giúp tập dữ liệu đạt trạng thái tinh khiết tuyệt đối trước khi tiến hành phân chia phân tập độc lập (80/10/10).

- **Phân tích tương quan độ dài (Scatter Plot):** Biểu đồ tương quan giữa số từ của câu ví dụ và câu dịch phổ thông cho thấy các điểm dữ liệu phân bố tập trung dày đặc xung quanh đường phân giác $y = x$. Sự phân bố tuyến tính chặt chẽ này chứng minh cấu trúc cú pháp và tỷ lệ tương đương từ vựng giữa phương ngữ miền Tây và tiếng phổ thông có độ đồng bộ rất cao, tạo điều kiện thuận lợi cho cơ chế tập trung (Luong Attention) ánh xạ chính xác các vùng ngữ nghĩa tương ứng giữa hai chuỗi.

Quy trình tách từ (Tokenization): Xử lý chuyển đổi chuỗi văn bản dạng thô thành danh sách các Token ID riêng lẻ, làm cơ sở dữ liệu đầu vào trực tiếp cho tầng nhúng (*Embedding Layer*) để khởi tạo các vectơ đặc trưng liên tục, phục vụ cho chu trình tính toán lan truyền tiến (Forward pass) của mạng Encoder.

3.4 Tiền xử lý và Chiến lược phân chia dữ liệu

Mặc dù tập dữ liệu gồm 10.511 cặp câu gốc đã đạt độ sạch cao, quy trình tiền xử lý văn bản vẫn được thực hiện một cách nghiêm ngặt nhằm đồng nhất định dạng:

- **Chuẩn hóa văn bản và loại bỏ ký tự nhiễu:** Tiến hành lọc và loại bỏ các ký tự nhiễu phát sinh ngẫu nhiên như "?" và "/". Thực hiện cắt bỏ các khoảng trắng thừa ở đầu/cuối câu, thu gọn các chuỗi khoảng trắng liên tiếp ở giữa câu để bộ tách từ (Tokenizer) cấp độ từ vựng hoạt động chính xác.
- **Chiến lược phân chia tập dữ liệu chống rò rỉ (Data Leakage):** Để đảm bảo tính khách quan và ngăn chặn hiện tượng rò rỉ dữ liệu (Data Leakage) trong thực nghiệm học máy, nhóm thực hiện phân chia 10.511 mẫu nguyên bản này thành 3 phân tập độc lập trước khi thực hiện bất kỳ bước tăng cường dữ liệu nào:
 - **Tập huấn luyện gốc (Original Training Set - 80%):** Dùng làm cơ sở để thực hiện các biện pháp làm giàu dữ liệu.
 - **Tập kiểm chứng (Validation Set - 10%):** Giữ nguyên bản để giám sát hàm loss khách quan.
 - **Tập kiểm thử (Testing Set - 10%):** Giữ nguyên bản để đánh giá năng lực dịch thuật cuối cùng.
- **Tăng cường và làm giàu dữ liệu (Data Augmentation):** Sau khi cô lập hoàn toàn tập Validation và Testing, nhóm tiến hành áp dụng các kỹ thuật làm giàu dữ liệu (Data Augmentation) độc lập trên tập Huấn luyện gốc. Quá trình tăng cường này đã mở rộng quy mô tập huấn luyện từ số lượng mẫu ban đầu lên thành **25.821**

mẫu, giúp mô hình học sâu (Seq2Seq, Transformer) có đủ không gian dữ liệu để hội tụ mà không làm mất đi tính tổng quát hóa khi kiểm thử trên dữ liệu thực tế.

3.5 Cấu trúc Pipeline

Data Pipeline

Luồng dữ liệu được thiết kế chặt chẽ nhằm ngăn chặn tuyệt đối hiện tượng rò rỉ dữ liệu:

- **Khám phá và Tiền xử lý:** Từ tập dữ liệu gốc `data_vietnamese_dialect.csv`, quá trình khám phá dữ liệu (EDA) và làm sạch văn bản được thực hiện thông qua `01_eda_and_cleaning.ipynb`.
- **Phân chia và Tăng cường:** Dữ liệu được chia theo tỷ lệ 80/10/10. Tập huấn luyện được đem đi tăng cường (Data Augmentation) lên khoảng 25.000 mẫu, trong khi tập kiểm chứng và kiểm thử được cô lập và lưu tại `data/processed/`.
- **Nạp dữ liệu (Data Loading):** Bộ tách từ (`tokenize_vocab.py`) xử lý ánh xạ từ vựng (với mô hình Seq2Seq Bi-LSTM), sau đó `data_loader.py` chịu trách nhiệm đóng gói Batch, thực hiện đệm (Padding) và che lấp (Masking) dựa trên giới hạn `Max_Sequence_Length`.

Modeling Pipeline

Dự án triển khai chiến lược thử nghiệm leo thang từ mức độ cơ bản đến phức tạp (lưu trữ tại `source/models/` và `source/baselines/`):

- **Baseline:** `rule_based.py` áp dụng phương pháp dịch trực tiếp dựa trên tập luật ánh xạ từ điển.
- **Mô hình học sâu:**
 - `seq2seq_lstm.py`: Kiến trúc mạng hồi quy tuần tự Bi-LSTM kết hợp cơ chế tập trung Luong Attention.
 - `transformer_full.py`: Tinh chỉnh toàn bộ trọng số (Full Fine-tuning) của mô hình tiền huấn luyện viT5.
 - `transformer_lora.py`: Áp dụng kỹ thuật tinh chỉnh tham số hiệu quả (PEFT/LoRA) trên nền viT5.

Pipeline Huấn luyện và Tối ưu (Training & Optimization)

- **Quản lý tham số:** Toàn bộ siêu tham số (Epochs, Batch size, Learning rate) được quản lý tập trung tại `config.py`.

- **Tối ưu hóa:** Tập `utils.py` chứa các hàm hỗ trợ cốt lõi như bộ tối ưu AdamW, lịch trình điều phối tốc độ học (Linear Warmup/Decay), và hàm ép buộc học tập (Scheduled Teacher Forcing) cho mô hình LSTM.
- **Lưu trữ (Checkpoints):** Trọng số mô hình tốt nhất (Best Checkpoint) và log dự đoán được tự động xuất ra thư mục `outputs/checkpoints/`.

Pipeline Đánh giá và Phân tích (Evaluation & Error Analysis)

Hệ thống kết hợp đánh giá song song hai khía cạnh định lượng và định tính:

- **Định lượng:** Script `plot_loss.py` vẽ biểu đồ hội tụ để kiểm tra hiện tượng Overfitting, trong khi `evaluate.py` tính toán tự động các chỉ số BLEU và ROUGE-L trên tập kiểm thử.
- **Định tính:** Kết quả dự đoán sai được phân tích sâu qua `error_analysis.ipynb` để trực quan hóa Wordcloud và phân loại các nhóm lỗi đặc thù (OOV, Hallucination, Polysemy).

Khâu Triển khai (Deployment)

- Toàn bộ quy trình suy luận (Inference) được đóng gói thành một ứng dụng Demo thông qua tệp `app.py`. Ứng dụng tích hợp trọng số mô hình đã huấn luyện, cho phép người dùng nhập văn bản phương ngữ và nhận kết quả tiếng Việt phổ thông theo thời gian thực.

Chương 4

Thực nghiệm & Đánh giá

4.1 Thiết lập cấu hình và Siêu tham số thực nghiệm

Để đảm bảo tính khách quan, minh bạch và khả năng tái lập (reproducibility) của thực nghiệm, toàn bộ các cấu hình hệ thống, siêu tham số huấn luyện và kiến trúc đặc thù của ba mô hình (Seq2Seq LSTM, viT5 Full Fine-Tuning, và viT5 LoRA) được quy định tập trung. Hệ thống sử dụng giá trị thiết lập hạt ngẫu nhiên toàn cục (Random Seed) cố định bằng 42. Đối với giai đoạn suy luận và giải mã (Inference Decoding), thuật toán Beam Search được cấu hình với kích thước chùm (Beam Size) bằng 4 và độ dài giải mã tối đa (Max_Decode_Length) giới hạn ở 50 token.


Chi tiết tập hợp các siêu tham số tối ưu hóa được áp dụng cho từng mô hình trong quá trình thực nghiệm được tổng hợp toàn diện trong Bảng 4.1.

Bảng 4.1: Tổng hợp siêu tham số huấn luyện và cấu hình kiến trúc của các mô hình


Siêu tham số / Cấu hình	Seq2Seq LSTM	viT5 Full FT	viT5 + LoRA
<i>1. Cấu hình kiến trúc nền tảng</i>			
Mô hình nền (Base Model)	Huấn luyện từ đầu	VietAI/vit5-base	VietAI/vit5-base
Số lượng tham số gốc	36M	226M	226M
Kích thước nhúng (embed_dim)	512	768	768
Kích thước tầng ẩn (hidden_dim)	726	–	–
Số tầng mạng (n_layers)	3	12 (Enc) / 12 (Dec)	12 (Enc) / 12 (Dec)
Hệ số Dropout	0.3	0.1	–
<i>2. Siêu tham số huấn luyện & Tối ưu hóa</i>			
Thuật toán tối ưu (Optimizer)	AdamW	AdamW	AdamW
Tốc độ học cơ sở (Learning Rate)	5×10^{-4}	2×10^{-5}	1×10^{-4}
Kích thước lô (Batch Size)	16	8	16
Số lượng Epoch tối đa	20	10	15
Suy giảm trọng số (Weight Decay)	1×10^{-4}	0.01	0.01
Cắt xén Gradient (Clip Grad)	1.0	1.0	1.0
Tỷ lệ khởi động (Warmup Ratio)	–	0.1 (10%)	0.1 (10%)
Ngưỡng dừng sớm (Patience)	5 Epochs	3 Epochs	3 Epochs
<i>3. Tham số đặc thù cấu hình</i>			
Chiến lược Teacher Forcing	Tuyến tính (0.9 $\rightarrow$ 0.5)	–	–
Hạng thích ứng LoRA (r)	–	–	8
Hệ số tỷ lệ LoRA (α)	–	–	16
Hệ số LoRA Dropout	–	–	0.05
Khối mục tiêu áp dụng LoRA	–	–	["q", "v"]
Độ chính xác số học	FP32	FP32	Mixed (FP16/BF16)

4.2 Biểu đồ hội tụ (Learning Curves)


Nhìn vào biểu đồ của hàm mất mát của các mô hình có thể đưa ra các ý về quá trình huấn luyện và mức độ hội tụ của các mô hình học sâu được triển khai, bao gồm LSTM, Transformer Full và Transformer LoRA. Thông qua sự biến thiên của hàm mất mát (Loss) trên tập huấn luyện (Training Loss) và tập kiểm định (Validation Loss), ta có thể đánh giá được khả năng học hỏi đặc trưng ngôn ngữ và phát hiện các hiện tượng quá khớp (Overfitting).



(a) Mô hình Transformer LoRA



(b) Mô hình Transformer Full



(c) Mô hình LSTM

Hình 4.1: Biểu đồ hội tụ hàm mất mát của các mô hình trong quá trình huấn luyện.

4.3 So sánh kết quả giữa các mô hình

Để có cái nhìn toàn diện về hiệu suất của các phương pháp, quá trình đánh giá được chia làm ba khía cạnh: đánh giá dựa trên quá trình tối ưu hóa (Loss), đánh giá dựa trên độ chính xác từ vựng (BLEU, ROUGE-L) và phân tích tính hạn chế của các thang đo này.

4.3.1 Đánh giá dựa trên hàm mất mát (Loss)

Đánh giá dựa trên biểu đồ hội tụ (Learning Curves) cho phép ta quan sát trực tiếp kết quả của quá trình huấn luyện.

- **Transformer LoRA:** Thể hiện sự ổn định vượt trội khi cả Train Loss và Val Loss đều giảm nhịp nhàng và ôm sát nhau. Điều này chứng minh mô hình học được đặc trưng tổng quát của phương ngữ Miền Tây mà không bị học vẹt.
- **Transformer Full:** Dù có tốc độ giảm Loss cực nhanh ở những epoch đầu, nhưng lại nhanh chóng bộc lộ sự bất ổn định khi Val Loss quay đầu tăng lên (Overfitting), buộc hệ thống phải kích hoạt cơ chế Early Stopping để bảo toàn kết quả.
- **Seq2Seq LSTM:** Đường Loss giảm rất chậm và chững lại ở mức khá cao so với kiến trúc Transformer, cho thấy giới hạn của mạng LSTM trong việc trích xuất ngữ cảnh dài.

4.3.2 Đánh giá dựa trên chỉ số BLEU và ROUGE-L

Kết quả kiểm thử định lượng trên tập Test được thống kê chi tiết trong Bảng 4.2.

Bảng 4.2: Kết quả thử nghiệm dịch tiếng Miền Tây sang tiếng Phổ thông trên tập Test

Mô hình / Phương pháp	Số lượng tham số	Thời gian huấn luyện	BLEU (%)	ROUGE-L (%)
Rule-Based Baseline	—	45 phút	12.45	34.20
Seq2Seq LSTM	36M	12 giờ	30.20	54.80
Transformer Full (ViT5-Base)	226M	2.5 giờ (Early Stop)	47.57	71.44
Transformer LoRA (ViT5)	226M (Trained 0.39%)	4.5 giờ	41.46	68.20

Nhìn vào bảng số liệu, có thể rút ra ba nhận xét chính.

Rule-Based xác nhận trần năng lực của ánh xạ tĩnh. RBMT chỉ đạt BLEU 12.45% và ROUGE-L 34.20% — thấp nhất trong tất cả các phương pháp và cách xa nhóm mô hình học sâu. Đáng chú ý là khoảng cách giữa BLEU và ROUGE-L của RBMT rất lớn (gần 3 lần): ROUGE-L đo độ khớp chuỗi con dài nhất nên không phạt nặng khi từ đúng nhưng sai vị trí, trong khi BLEU phạt trực tiếp các n-gram sai thứ tự. Điều này phản ánh đúng bản chất của RBMT: “biết từ nhưng không biết câu” — từ đúng nhưng cấu trúc sai.

Transformer Full đạt điểm tuyệt đối cao nhất nhưng tiềm ẩn rủi ro overfitting. Transformer Full (ViT5-Base fine-tune toàn bộ tham số) đạt BLEU 47.57% và ROUGE-L 71.44% — cao nhất trong bảng. Tuy nhiên, con số này cần được đọc cùng với biểu đồ hội tụ ở Hình 4.1b: Val Loss của mô hình này đã bắt đầu tăng trở lại trước khi bị Early Stopping dừng lại. Điều đó có nghĩa là điểm BLEU 47.57% là kết quả tại checkpoint tốt nhất được lưu lại — không phản ánh xu hướng huấn luyện dài hạn nếu tiếp tục chạy

thêm epoch. Nói cách khác, mô hình đã chạm đỉnh hiệu suất sớm do học quá khớp trên tập huấn luyện, và Early Stopping can thiệp đúng lúc để “đóng băng” kết quả tốt nhất đó.

Transformer LoRA đánh đổi một phần điểm số để đổi lấy sự ổn định và hiệu quả tham số. LoRA đạt BLEU 41.46% và ROUGE-L 68.20% — thấp hơn Transformer Full lần lượt 6.11 điểm và 3.24 điểm ROUGE-L. Tuy nhiên, đây là kết quả của một mô hình **chỉ huấn luyện 0.39% số tham số** ($\approx 880K$ so với $\sim 226M$ của Full), không có dấu hiệu overfitting, và đường Val Loss vẫn còn dư địa để tiếp tục giảm nếu huấn luyện thêm.

4.3.3 Ưu và khuyết điểm của việc đánh giá bằng Loss so với BLEU/ROUGE

Trong thực nghiệm KHD, việc chỉ nhìn vào một khía cạnh đánh giá có thể dẫn đến những nhận định sai lầm. Qua bài toán dịch phương ngữ này, ta thấy rõ sự bù trừ cho nhau giữa hai phương pháp đo lường:

- **Đánh giá bằng Loss:**


- *Ưu điểm:* Phản ánh trung thực nhất việc thuật toán có đang tối ưu hóa đúng hướng hay không, giúp phát hiện ngay lập tức hiện tượng Overfitting/Underfitting.
- *Khuyết điểm:* Con số Loss thấp không đồng nghĩa với việc câu văn sinh ra sẽ tự nhiên và hợp logic với con người.

- **Đánh giá bằng độ khớp từ (BLEU/ROUGE):**

- *Ưu điểm:* Chấm điểm trực tiếp trên văn bản đầu ra (so sánh n-gram với đáp án chuẩn), mô phỏng gần hơn với cách con người đánh giá một câu dịch.
- *Khuyết điểm (Điểm mù ảo):* Do đặc thù của bài toán dịch tiếng Miền Tây, phần lớn cấu trúc câu và các từ phổ thông xung quanh vẫn được giữ nguyên, chỉ thay đổi một vài từ vựng địa phương. Thang đo BLEU tính toán độ trùng lặp trên **toàn bộ câu**. Do đó, có những trường hợp mô hình **dịch sai hoàn toàn từ địa phương trọng tâm**, nhưng vì các từ phổ thông xung quanh vẫn khớp với đáp án, điểm BLEU của câu đó **vẫn cao một cách giả tạo**.

Chính vì hạn chế ("điểm mù") này của BLEU, ta không thể phó mặc hoàn toàn vào các con số thống kê. Để đánh giá thực chất năng lực của mô hình, bước tiếp theo bắt buộc phải thực hiện là Phân tích lỗi (Error Analysis) dựa trên quan sát thủ công.

- *Giữ nguyên từ gốc:* Ví dụ với câu “Một cái **mật** măng ngon thiệt”, mô hình dự đoán thành “Một cái **mật** măng ngon thật” (không dịch được chữ “mật” thành “mâm”).
- *Đoán mò tạo ra từ vô nghĩa:* Ở câu “Thất tình hay sao mà buồn **nhau nháu** vậy ông bạn”, mô hình đã dịch chữ “nhau nháu” thành “...buồn **nhau không nhẽo**”, làm sai lệch hoàn toàn biểu cảm.
- **Lỗi Hallucination (Hiện tượng sinh ảo):** Do đặc tính của các mô hình ngôn ngữ sinh thành (Generative AI), hệ thống đôi khi cố gắng "làm mượt" câu văn bằng cách tự suy diễn ngữ cảnh.
 - *Ví dụ 1:* Câu “Ngày nào cũng lo ăn cho bấy nhiêu người, chạy vậy là **khảm** thiệt chứ” được mô hình dịch thành “...chạy thế này là **mệt** thật chứ”. Dù câu văn đọc có vẻ hợp lý, nhưng nó đã làm mất đi ý nghĩa “bỏ hơi tai / quá tải” của từ “khảm”.
 - *Ví dụ 2:* Từ “lui hủi” bị mô hình ảo giác biến thành hành động “lượn lờ” thay vì “sục sạo ngửi”.
- **Lỗi Polysemy (Lỗi đa nghĩa / Hiểu sai ngữ cảnh):** Từ vựng Miền Tây thường có hiện tượng chuyển nghĩa phức tạp tùy thuộc vào bối cảnh giao tiếp, khiến mô hình chọn nhầm nét nghĩa.
 - *Ví dụ:* Trong câu “Ở dưới quê người ta hay **tráo** lăm...”, từ “tráo” ở đây mang hàm ý là “xảo trá / đánh tráo”. Tuy nhiên, mô hình lại áp dụng nét nghĩa sai và dịch thành “...người ta hay **trố mắt** lăm”.
- **Lỗi Literal Translation (Dịch Word-by-Word):** Đây là lỗi dịch quá sát nghĩa đen khiến câu tiếng Phổ thông đầu ra bị "sượng", thiếu tự nhiên. Thay vì hiểu toàn bộ ý nghĩa của một quán ngữ, mô hình dịch từng chữ một làm mất đi tính biểu cảm vốn có của người Miền Tây.



(a) Ví dụ minh họa lỗi Hallucination

	Câu gốc (Input)	Đúng chuẩn (Reference)	LoRA Dịch (Prediction)	error_type
0	Gió quạt nhẹ hều vậy, ngồi cũng nóng hằm hạp à.	Luồng gió quá yếu nên vẫn cảm thấy nóng bức.	Gió thổi nhẹ nhàng thế này, ngồi cũng nóng hằm hạp à.	OOV
1	Bữa nay tui thấy người nó lừ đừ, chắc tại thời tiết đổi mùa.	Hôm nay tôi thấy người nó đờ, chắc tại thời tiết đổi mùa.	Hôm nay tôi thấy người nó lừ đừ, chắc tại thời tiết đổi mùa.	OOV
2	Nghe nói bên đó có bùa chú, ai cũng đồn hết trơn.	Nghe kể rằng họ sở hữu bùa chú khá linh nghiệm.	Nghe nói bên đó có bùa chú, ai cũng đồn hết cả.	OOV
3	Thất tình hay sao mà buồn nhau nhàu vậy ông bạn.	Thất tình hay sao mà buồn rười rượi vậy ông bạn.	Thất tình hay sao mà buồn nhau nhõng nhẽo thế anh bạn.	OOV
4	Ngày nào cũng lo ăn cho bấy nhiêu người, chạy vậy là khảm thiệt chứ.	Ngày nào cũng lo ăn cho bấy nhiêu người, chạy thế này là bỏ hơi tại thật đấy.	Ngày nào cũng lo ăn cho bao nhiêu người, chạy thế này là mệt thật chứ.	Hallucination
5	Con mèo cứ lúi húi quanh cái tủ chén hoải.	Con mèo cứ sục sạo người quanh cái tủ chén suốt.	Con mèo cứ lượn lờ quanh cái tủ chén mãi.	Hallucination
6	Gió lao rào vậy làm tàu cau nhõng nhánh, tui ngồi đây hoải hổng chán.	Gió xào xạc thế này làm tàu cau lũng liếng, tôi ngồi đây mãi không chán.	Gió lao xao thế này làm tàu cau nhõng nhánh, tôi ngồi đây mãi không chán.	OOV
7	Nhà bữa nay đám tiệc gì mà gián giá dữ vậy anh Tư?	Nhà có tiệc gì mà bày biện linh đình thế này	Nhà hôm nay có đám tiệc gì mà hoành tráng thế anh Tư?	OOV
8	Coi chừng ma đa rù gió vậy đó, ông cần thận nghe.	Coi chừng ma nước kéo chân thế này đấy, anh cần thận nhè.	Coi chừng ma đa rù gió thế này đấy, anh cần thận nghe.	OOV
9	Cá chạch lấu đem kho nghệ ăn hao cơm dữ lắm nghen con.	Cá chạch lấu mang kho nghệ ăn tốn cơm nhiều lắm nhè con.	Cá chạch lấu đem kho nghệ ăn hao cơm lắm đấy nhè con.	OOV
10	Cái thắng đó cái giống không hề, mầy cái với nó làm chi	Cái thắng đó chỉ toàn cái cùn, anh cái với nó làm gì	Cái thắng đó cái giống không hề, mầy cái với nó làm gì	OOV

(b) Ví dụ minh họa lỗi OOV và Literal Translation

Hình 4.3: Các trường hợp dự đoán sai tiêu biểu trích xuất từ tập kiểm thử.

Từ các ví dụ trực quan trong Hình 4.3, ta có thể thấy rõ sự khác biệt giữa câu máy dịch và câu chuẩn. Lỗi Hallucination (Hình 4.3a) cho thấy dù câu văn đầu ra rất "mượt" về mặt ngữ pháp, nhưng lại xa rời ngữ nghĩa gốc. Trong khi đó, các lỗi tại Hình 4.3b lại phản ánh sự lúng túng của mô hình khi đối mặt với các từ vựng địa phương đặc thù, dẫn đến việc dịch thiếu tự nhiên hoặc sai lệch hoàn toàn so với ý định biểu đạt của người dùng.

Chương 5

Kết luận

5.1 Ý nghĩa thực tiễn của đề tài

Kết quả nghiên cứu của đề tài không chỉ dừng lại ở các chỉ số đánh giá mô hình mà còn mang lại những giá trị ứng dụng thiết thực, góp phần tạo cầu nối giữa giá trị văn hóa truyền thống và công nghệ hiện đại.

5.1.1 Bảo tồn và phát huy di sản ngôn ngữ Nam Bộ

Phương ngữ Nam Bộ, với hệ thống từ vựng, ngữ pháp và thanh điệu đặc sắc, là một thành tố quan trọng trong di sản văn hóa phi vật thể của Việt Nam. Tuy nhiên, dưới áp lực của quá trình đô thị hóa và sự lên ngôi của ngôn ngữ chuẩn trên các phương tiện truyền thông đại chúng, nhiều sắc thái ngôn ngữ địa phương đang dần bị mai một.

- **Lưu trữ số hóa:** Đề tài đóng vai trò như một kho lưu trữ số hóa thông minh, giúp ghi nhận và định lượng các đặc trưng ngôn ngữ mà từ điển truyền thống chưa truyền tải hết.
- **Cầu nối thế hệ:** Bằng cách chuẩn hóa phương ngữ, mô hình giúp thế hệ trẻ dễ dàng tiếp cận và thấu hiểu văn hóa của cha ông, duy trì sợi dây liên kết giữa quá khứ và hiện đại thông qua công nghệ NLP.

5.1.2 Hỗ trợ chuẩn hóa và tối ưu hóa văn bản trong môi trường hành chính

Trong các hệ thống hành chính, giáo dục hoặc báo chí khu vực, việc chuyển đổi linh hoạt giữa văn bản phương ngữ và tiếng Việt phổ thông là một nhu cầu cấp thiết nhằm đảm bảo sự minh bạch và đồng bộ thông tin.

- **Chuẩn hóa văn bản:** Đề tài cung cấp một công cụ hỗ trợ biên dịch tự động cho các nhà làm nội dung, giúp quá trình soạn thảo văn bản trở nên chuyên nghiệp, nhất quán mà vẫn giữ được "hồn cốt" của văn phong vùng miền khi cần thiết.
- **Giảm thiểu rào cản thông tin:** Hỗ trợ các cơ quan chính quyền địa phương trong việc truyền tải thông tin đến người dân bằng ngôn ngữ gần gũi, qua đó nâng cao hiệu quả tương tác và phản hồi của người dân.

5.1.3 Tiềm năng tích hợp sâu vào hệ sinh thái AI

Mô hình nghiên cứu mở ra triển vọng ứng dụng rộng rãi trong các nền tảng công nghệ hiện nay:

1. **Hệ thống Chatbot và trợ lý ảo:** Tích hợp mô hình vào các chatbot dịch vụ công hoặc thương mại điện tử giúp hệ thống không chỉ "hiểu" mà còn "thấu cảm" với người dùng miền Nam. Việc phản hồi tự nhiên, đúng giọng điệu địa phương giúp tăng mức độ hài lòng và tạo sự tin tưởng tuyệt đối.
2. **Hệ thống dịch thuật máy (NMT) chuyên biệt:** Kết quả của đề tài có thể được sử dụng như một module tiền xử lý (preprocessing module) cho các hệ thống NMT lớn, giúp cải thiện đáng kể độ chính xác khi xử lý các văn bản có chứa từ ngữ phương ngữ – một "điểm mù" của hầu hết các mô hình NMT phổ thông hiện nay.
3. **Công cụ hỗ trợ giáo dục:** Là công cụ hỗ trợ người học (đặc biệt là người nước ngoài hoặc người vùng khác) tìm hiểu sự đa dạng của tiếng Việt. Đồng thời, cung cấp tài liệu thực nghiệm giá trị cho các nhà ngôn ngữ học trong việc phân tích sự biến đổi từ vựng theo thời gian.

5.2 Đóng góp

Thông qua quá trình nghiên cứu, xây dựng hệ thống và thực nghiệm đối chứng, đề tài đã đạt được các đóng góp quan trọng cả về mặt dữ liệu lẫn giá trị khoa học thực tiễn:

- **Xây dựng và chuẩn hóa kho ngữ liệu đặc thù:** Nhóm đã thiết lập thành công bộ dữ liệu song ngữ gốc gồm 10.511 cặp câu "Miền Tây — Phổ thông" hoàn toàn sạch (0 giá trị null, không trùng lặp). Quy trình phân chia dữ liệu (80/10/10) được thực hiện nghiêm ngặt trước khi áp dụng kỹ thuật tăng cường dữ liệu (Data Augmentation) độc lập trên tập huấn luyện để mở rộng lên quy mô 25.821 mẫu. Đây là một chiến lược thiết kế pipeline sạch, ngăn chặn triệt để hiện tượng rò rỉ dữ liệu (Data Leakage) và tạo tiền đề ngữ liệu quý giá cho các nghiên cứu về phương ngữ Việt Nam.
- **Thiết lập hệ thống đánh giá đối chứng toàn diện (Comprehensive Benchmark):** Đề tài đã triển khai và so sánh thực nghiệm thành công trên 4 cấp độ kiến trúc: từ phương pháp dựa trên luật (Rule-based) đến các kiến trúc học sâu truyền thống (Seq2Seq Bi-LSTM) và các mô hình ngôn ngữ lớn tiên tiến (Pre-trained Transformer tinh chỉnh bằng kỹ thuật LoRA).
- **Chỉ ra các đặc trưng ngôn ngữ và ranh giới kiến trúc:** Quá trình thực nghiệm đã làm rõ sự đánh đổi giữa tài nguyên tính toán và hiệu năng ngôn ngữ. Kết quả chỉ ra rằng mạng hồi quy tuần tự (Seq2Seq) gặp giới hạn lớn về khả năng khái quát

hóa đối với không gian từ vựng thừa thớt, trong khi giải pháp mã nguồn mở kết hợp tinh chỉnh tham số hiệu quả (LoRA) mang lại năng lực vượt trội trong việc nắm bắt ngữ nghĩa đa tầng.

5.3 Hạn chế còn tồn tại

Mặc dù đạt được những kết quả khả quan trên tổng thể hệ thống, đề tài vẫn tồn tại những hạn chế cốt lõi cần được nhìn nhận một cách khách quan giữa các nhóm kiến trúc thực nghiệm:

- **Giới hạn dung lượng và hiện tượng suy giảm hiệu năng của mô hình Seq2Seq với 36M tham số:** Trong các pha thực nghiệm đối chứng, mô hình Seq2Seq Bi-LSTM bộc lộ điểm yếu rất lớn về mặt kiến trúc khi được cấu hình mở rộng lên quy mô **36M tham số**. Việc tăng kích thước chiều ẩn (*hidden size*) và số tầng mạng vô tình khiến không gian tham số của LSTM trở nên quá lớn so với dung lượng thừa thớt của tập dữ liệu phương ngữ. Hệ quả là mô hình rơi vào bẫy quá khớp (*Overfitting*) nghiêm trọng từ rất sớm; đường cong học tập ghi nhận giá trị Validation Loss bị kẹt hoàn toàn ở mức cao (**4.x**) và không thể tối ưu thêm. Điều này chứng minh giới hạn cố hữu của kiến trúc mạng hồi quy truyền thống: dù có tăng dung lượng tham số lên mức tối đa, cơ chế nén toàn bộ ngữ nghĩa chuỗi vào một vectơ trạng thái ẩn cố định vẫn tạo ra hiện tượng thắt nút cổ chai (*bottleneck*), gây mất mát thông tin trầm trọng khi xử lý khẩu ngữ địa phương dài hoặc có cấu trúc phức tạp.
- **Hiện tượng sinh ảo (Hallucination) và sự phụ thuộc ngữ cảnh của Transformer LoRA:** Mặc dù mô hình Transformer LoRA cho hiệu suất tổng thể tốt nhất (BLEU đạt 41.46%), hệ thống vẫn đối mặt với bẫy sinh ảo đặc trưng của các kiến trúc ngôn ngữ lớn dạng sinh thành (*Generative AI*). Do xu hướng tự làm mượt văn bản dựa trên tri thức nền tiền huấn luyện, mô hình đôi khi tự suy diễn ngữ cảnh một cách thô bạo, dẫn đến việc dịch sai lệch hoặc làm biến mất hoàn toàn các từ vựng mang tính biểu cảm đặc thù của người dân Nam Bộ (tiêu biểu như các trường hợp dịch lỗi từ "*khảm*", "*lui hử*").
- **Thách thức xử lý từ vựng ngoài từ điển (OOV) và lỗi đa nghĩa (Polysemy):** Hệ thống nói chung vẫn chưa giải quyết triệt để các trường hợp từ vựng địa phương hiếm gặp hoặc phát âm trại đi ("*mứt*", "*nhau nháu*"). Sự thiếu hụt ngữ cảnh thô khiến mô hình dễ chọn sai nét nghĩa khi từ vựng bị chuyển dịch môi trường giao tiếp (như từ "*tráo*"), dẫn đến các câu dịch đầu ra bị sượng do xu hướng dịch thô từng từ một (*Literal Translation*).
- **Ràng buộc tài nguyên và nghẽn tính toán tuần tự:** Kiến trúc Seq2Seq bắt buộc phải tính toán tuần tự theo từng bước thời gian (*Time-steps*), khiến tốc độ

huấn luyện mô hình 36M tham số này bị chậm nghiêm trọng, không tận dụng được khả năng tính toán song song của phần cứng GPU Tesla T4. Ràng buộc này buộc nhóm phải hy sinh tài nguyên: rút ngắn kích thước chặn chuỗi tối đa xuống mức $Max_Sequence_Length = 17$ từ nhằm bảo toàn bộ nhớ đồ họa, phần nào cản trở mô hình khai thác sâu các mối quan hệ ngữ nghĩa dài hạn.

5.4 Hướng phát triển trong tương lai

Để khắc phục các hạn chế đã được định lượng và phân tích, nhóm đề xuất các hướng cải tiến và mở rộng nghiên cứu trong tương lai:

- **Khắc phục lỗi OOV bằng kỹ thuật Tokenization tiên tiến:** Nghiên cứu áp dụng các bộ tách từ cấp độ cụm từ hoặc phân rã từ tổ chuyên biệt cho phương ngữ, kết hợp mở rộng kho từ điển lóng Miền Tây để triệt tiêu hiện tượng từ vựng ngoài danh mục.
- **Giảm thiểu sinh ảo bằng cơ chế kiểm chứng lai (Hybrid Translation Pipeline):** Phát triển hệ thống dịch máy kết hợp giữa sức mạnh ngữ nghĩa của Transformer LoRA và lớp kiểm soát luật từ vựng (Rule-based Dictionary) tại pha hậu xử lý, nhằm "giữ chân" mô hình không tự suy diễn sai lệch các từ khóa văn hóa quan trọng.
- **Mở rộng quy mô sang hệ thống dịch đa phương ngữ (Multilingual NMT):** Tăng cường thu thập thêm dữ liệu từ các vùng miền khác (phương ngữ miền Trung, miền Bắc) để nâng cấp mô hình thành một hệ thống dịch máy đa phương ngữ toàn diện, hướng tới ứng dụng thực tế trong việc hỗ trợ giao tiếp và bảo tồn văn hóa ngôn ngữ số.

Tài liệu tham khảo

- [1] A. Zhang, Z. C. Lipton, M. Li, and A. J. Smola, *Dive into Deep Learning*. Cambridge University Press, 2023.
- [2] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.
- [3] A. Vaswani et al., “Attention Is All You Need,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.
- [4] C. Raffel et al., “Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer,” *Journal of Machine Learning Research*, vol. 21, no. 140, pp. 1–67, 2020.
- [5] L. Phan et al., “ViT5: Pretrained Text-to-Text Transformer for Vietnamese Language Generation,” *Proceedings of LREC 2022*, 2022.
- [6] A. Conneau et al., “Unsupervised Cross-lingual Representation Learning at Scale,” *Proceedings of ACL 2020*, 2020.
- [7] E. J. Hu et al., “LoRA: Low-Rank Adaptation of Large Language Models,” *International Conference on Learning Representations (ICLR)*, 2022.
- [8] A. Aghajanyan, S. Gupta, and L. Zettlemoyer, “Intrinsic Dimensionality Explains the Effectiveness of Language Model Fine-Tuning,” *Proceedings of ACL-IJCNLP 2021*, 2021.
- [9] D. P. Kingma and J. Ba, “Adam: A Method for Stochastic Optimization,” *International Conference on Learning Representations (ICLR)*, 2015.
- [10] I. Loshchilov and F. Hutter, “Decoupled Weight Decay Regularization,” *International Conference on Learning Representations (ICLR)*, 2019.
- [11] A. Paszke et al., “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” *Advances in Neural Information Processing Systems*, vol. 32, 2019.
- [12] T. Wolf et al., “Transformers: State-of-the-Art Natural Language Processing,” *Proceedings of EMNLP: System Demonstrations*, pp. 38–45, 2020.
- [13] S. Bengio, O. Vinyals, N. Jaitly, and N. Shazeer, “Scheduled Sampling for Sequence Prediction with Recurrent Neural Networks,” *Advances in Neural Information Processing Systems*, vol. 28, 2015.

- [14] I. Sutskever, O. Vinyals, and Q. V. Le, “Sequence to Sequence Learning with Neural Networks,” *Advances in Neural Information Processing Systems*, vol. 27, 2014.
- [15] N. Srivastava et al., “Dropout: A Simple Way to Prevent Neural Networks from Overfitting,” *Journal of Machine Learning Research*, vol. 15, no. 56, pp. 1929–1958, 2014.
- [16] L. Prechelt, “Early Stopping — But When?” in *Neural Networks: Tricks of the Trade*, Springer, 1998.
- [17] D. Bahdanau, K. Cho, and Y. Bengio, “Neural machine translation by jointly learning to align and translate,” *arXiv preprint arXiv:1409.0473*, 2014.

Bảng 5.1: Bảng phân công công việc của nhóm

STT	Tên thành viên	MSSV	Công việc thực hiện	Đóng góp
1	Nguyễn Đỗ Khánh Ngọc	23280008	- Triển khai Rule Based - Triển khai LoRA cho viT5 - Viết Chương 2, 4	100%
2	Thái Ngọc Thanh Mai	23280018	- Thu thập và tiền xử lý dữ liệu - Huấn luyện mô hình viT5 Full Fine-tuning - Viết chương 2, 3	100%
3	Nguyễn Ngọc Minh	223280029	- Xây dựng mô hình Seq2Seq Bi-LSTM - Thu thập và tiền xử lý dữ liệu - Viết chương 1, 2, 5	100%
Tổng cộng				100%